# Algorithmen & Komplexität

# Theoretische Informatik

Roman Wetenkamp

7. Juni 2021



# Inhaltsverzeichnis

I.	Grundlagen der Algorithmik	5
1.	Der Algorithmusbegriff	5
2.	Effizienz / Komplexität	6
3.		
4.	Rekursionsgleichungen4.1. Mastertheorem4.2. Auflösungsverfahren	9 10
5.	Bestimmung von Komplexitäten  5.1. Rechengesetze der O-Notation	13
II.	Suchalgorithmen	17
6.	Lineare Suche	17
7.	Binäre Suche	18
8.	Textsuche8.1. Einfache Textsuche8.2. Knuth-Morris-Pratt-Algorithmus (KMP)8.3. Boyer-Moore-Algorithmus	20
111	. Sortieralgorithmen	25
9.	Allgemeines und Eigenschaften	25
10	. Insertion Sort	26
11	. Bubblesort	27
12	. Mergesort	28
13	. Quicksort	30
14	. Weitere Sortieralgorithmen	31
15	. Allgemeine Komplexitätsbetrachtung von Sortieralgorithmen	32

IV. Bäume	34
16. Der Wurzelbaum	34
17. Binäre Bäume         17.1. Traversierung von Binärbäumen	<b>36</b> 36 37
18. AVL-Bäume	38
V. Heaps	43
19. Herstellen der Heap-Eigenschaft	44
20. Einfügen eines Elementes	45
21. Löschen des größten Elements	46
22. Heapsort	46
VI. Graphentheorie	49
23. Typisierung und Eigenschaften	49
24. Adjazenzmatrizen und -listen	51
VII. Lösungen	53
25. Grundlagen der Algorithmik	<b>5</b> 3
26. Suchalgorithmen	56
27. Sortieralgorithmen	56
28. Bäume	56
29. Heaps	56
VIII.Verzeichnisse	57

## **Vorwort**

Die theoretische Informatik ist genau das Thema, vor dem ich vor Beginn meines Studiums am meisten Respekt hatte ... Und das ist es neben den anderen Mathematik-Vorlesungen bis heute: Theoreme, Kalküle und Formeln sind nun einmal nicht die Dinge, mit denen sich die Masse der Informatikstudierenden gerne befasst, mich eingeschlossen. Mit einer gerade eben bestandenen Logikklausur im ersten Semester sind dies Gründe genug dafür ergänzendes, motivierendes und begreifbares Material zusammenzustellen, dass mich einerseits akut durch die Klausur dieses Semesters bringt und hoffentlich auch für andere einen Nutzen hat. Geteiltes Leid ist halbes Leid!

Hier möchte ich den Vorlesungsstoff auf meine Art zusammenfassen und komplettieren, um Beispiele ergänzen und mit Aufgaben versehen, wie ich sie in der Vorlesung oder weiteren Büchern antraf. Ich persönlich lerne durch Aufgaben einfach am besten und für diejenigen, denen es auch so geht, gibt es davon hier ausreichend. Lösungen finden sich (in einigen Wochen) im Anhang.

Viel Erfolg!

Roman Wetenkamp Mannheim, den 7. Juni 2021

Warnung Das Studium an einer Dualen Hochschule unterscheidet sich von dem Studium an Universitäten oder regulären Fachhochschulen insbesondere dadurch, dass aufgrund der Dualität zwischen Theorie und Praxis meist nur die Hälfte der Zeit zur Vermittlung des Stoffes zur Verfügung steht (wenn dann auch intensiver). Daher gehen Sie bitte nicht davon aus, dass Sie dieses Skript für Klausuren in regulären Vollzeitstudiengängen vorbereitet!

Hinweis Dieses Dokument ist kein Vorlesungsmaterial, hat keineswegs den Anspruch auf Vollständigkeit und enthält mit Sicherheit Fehler. Desweiteren ist es noch lange nicht vollendet (es ist infrage zustellen, ob es das je sein wird), und doch möchte ich Sie ermutigen, beizutragen! Jegliche Fehler, Probleme oder Anmerkungen können Sie mir gerne über das dazugehörige GitHub-Repository unter der URL https://github.com/RWetenkamp/algokomp zukommen lassen. Ebenso sind Sie völlig frei darin, dieses Dokument für Ihre legitimen Zwecke zu nutzen – bitte beachten Sie dennoch Ihr Gewissen. Danke!

# Teil I.

# Grundlagen der Algorithmik

# 1. Der Algorithmusbegriff

Wie der Titel dieses Moduls schon verrät, befassen wir uns mit Algorithmen: Jenen nebulösen Dingen, die uns mit ähnlich Denkenden und Interessierten in Social-Media-Plattformen zusammenbringen, komplexe mathematische Berechnungen ausführen und zunehmend mehr an Einfluss in unserem Leben gewinnen. Wir betrachten hier nun die Wortherkunft, definieren den Begriff anschließend und gehen auf Eigenschaften eines solchen ein.

**Wortherkunft** Der Begriff "Algorithmus" besteht zum einen aus dem altgriechischen Wort arithmos – Zahl und zum anderen geht er zurück auf den persischen Mathematiker AL-Charismi (780-846 n. Chr.), dessen Werk "Algorismus" schon eine gewisse Nähe zum heute üblichen Begriff offenbart. [Enz20]

**Definition 1.** Unter einem Algorithmus verstehen wir eindeutige Verarbeitungsvorschriften zur Lösung eines Problems oder einer Problemklasse. Daran geknüpft ist der Gedanke des EVA-Prinzips: Eine Eingabe wird verarbeitet und auf Grundlage dessen wird eine Ausgabe erzeugt, ein Algorithmus ist hier für die Verarbeitung bis zur Ausgabe notwendig.

Algorithmen finden in einer Vielzahl von Bereiches unseres Lebens Einsatz:

- Zur Untersuchung großer Datenmengen
- Zur Kommunikation/Suche im Internet
- In bildgebenden Verfahren oder diagnostischen Anwendungen der Medizin
- In Assistenzsystemen im Auto
- Bei der Partnersuche über Online-Dating-Plattformen

Damit finden wir intuitiv eine Begründung für die Untersuchung von Algorithmen.

Bemerkung 1. Ein Algorithmus ist von einem Programm unbedingt abzugrenzen: Der Algorithmus bezeichnet ein abstraktes Konzept zur Lösung eines gegebenen Problems während ein Programm die konkrete Umsetzung eines Algorithmus in einer Programmiersprache ist. (Implementierung)

Bei der Betrachtung von Algorithmen betrachten wir die folgenden drei Ziele:

- Korrektheit
- Effizienz
- Einfachheit

**Einfachheit** Aus wirtschaftlichen Gründen besteht ein Interesse daran, dass ein Algorithmus so einfach wie möglich ist, beispielsweise in Bezug auf Implementierungskosten. Ein weiterer Aspekt besteht in der Prüfung auf Korrektheit: Zu einem zu komplexen Algorithmus lässt sich nur schwer feststellen, ob dieser korrekt ist.

Korrektheit Die Korrektheit ist die zentrale Eigenschaft eines Algorithmus – Wenn ein Algorithmus nicht das leistet, was er vorgibt zu leisten oder was von ihm erwartet wird, ist er wertlos. Die Spezifikation beschreibt das exakte Verhalten unter Angabe von einer Vorbedingung (Zustand der Daten vor der Ausführung) und einer Nachbedingung (erwünschter Zustand nach der Ausführung).

**Definition 2.** Ein Algorithmus heißt **partiell korrekt**, falls aus erfüllter Vorbedingung die Nachbedingung folgt.

Ein Algorithmus heißt **total korrekt**, falls er partiell korrekt ist und nach endlich vielen Schritten terminiert.

Die Korrektheit eines Algorithmus kann manuell, per Implementierung oder mathematisch verifiziert werden, wobei letztere Variante häufig vorzuziehen ist.

Bemerkung 2. Nicht jeder Algorithmus muss für jede Eingabe terminieren. Unter dem Halteproblem versteht man die Frage, ob ein Algorithmus nach endlich vielen Schritten terminiert. Diese Frage ist algorithmisch nicht entscheidbar, wie Alan Turing feststellte. Stattdessen muss die Termination für jeden Algorithmus einzeln entschieden werden.

# 2. Effizienz / Komplexität

Weitaus komplexer als die Frage der Einfachheit oder Korrektheit ist jene der Komplexität selbst:

**Definition 3.** Die Effizienz / Komplexität eines Algorithmus ist ein Maß für die Menge an Ressourcen (Rechenzeit oder Speicherbedarf), die er benötigt.

Dabei ist zu beachten, dass es für ein Problem häufig mehrere Algorithmen gibt, die sich in ihrer Komplexität unterscheiden. Daher muss die Komplexität für jeden Algorithmus einzeln bestimmt werden. Dieses Skript befasst sich im Wesentlichen nur mit der Rechenzeit.

Für eine wirklich präzise Aussage über die Rechenzeit wäre es erforderlich, für jede Implementation eines Algorithmus in einer Programmiersprache einzeln festzustellen, welche Rechenzeit jede einzelne Operation auf dem spezifischen Prozessor des Testsystems benötigt. Da diese Aussagen mittlerweile aufgrund der Entwicklungen auf dem Prozessormarkt an Relevanz verlieren, verlagert sich die Betrachtung auf die Komplexität eines Algorithmus.

Die Komplexität eines Algorithmus kann folglich keine genaue Angabe in einer Zeiteinheit sein, die beispielsweise aussagt, wie schnell denn nun wirklich der größte gemeinsame Teiler von 443 und 123 mithilfe des euklidischen Algorithmus berechnet werden kann, sondern ist ein abstraktes Konzept, das Vergleiche zwischen Algorithmen ermöglichen soll:

- Abstraktion konstanter Faktoren
- Abstraktion unbedeutender Terme
- Wachstumsverhalten der Laufzeit bei Veränderung der Größe der Eingabe

Diese Abstraktion motiviert nun den folgenden Abschnitt.

# 3. Maß der Komplexität: O-Notation

Nach dem Mathematiker EDMUND LANDAU definieren wir in Bezug auf das Wachstum von Funktionen eine "obere Schranke" und nennen diese O(f). Falls eine Funktion g nicht schneller wächst als f, so sagen wir, dass  $g \in O(f)$ . Eine ebenfalls übliche, jedoch irritierende Schreibweise ist g = O(f).

**Definition 4.** Sei  $\mathbb{R}_+ := \{x \in \mathbb{R} \mid x > 0\}$  und  $\mathbb{R}_+^{\mathbb{N}} := \{f \mid f \text{ ist eine Funktion der Form } f : \mathbb{N} \to \mathbb{R}_+\}$ 

Sei  $g \in \mathbb{R}_+^{\mathbb{N}}$  gegeben. Dann ist die Menge aller Funktionen, die höchstens so schnell wachsen wie g definiert als:

$$O(g) := \{ f \in \mathbb{R}_+^{\mathbb{N}} \mid \exists n_0 \in \mathbb{N} : \exists c \in \mathbb{R}_+ : \forall n \in \mathbb{N} : (n \ge n_0 \Rightarrow f(n) \le c \cdot g(n)) \}$$

Die O-Notation gibt folglich eine Menge vergleichbarer Funktionen an, die es ermöglicht, die Komplexität eines Algorithmus abzuschätzen.

Beispiel 1. Behauptung:  $3n^3 + 2n^2 + 7 \in O(n^3)$ 

Beweis. Gesucht ist eine Konstante  $c \in \mathbb{R}_+$  und eine Konstante  $n_0 \in \mathbb{N}$ , sodass für alle  $n \in \mathbb{N}$  mit  $n \ge n_0$  gilt:  $3n^3 + 2n^2 + 7 < c \cdot n^3$ 

 $3n + 2n + 1 \le c \cdot n$ 

Wähle  $n_0 := 1$  und  $c := 12^{-1}$ Sei nun

$$1 \le n \tag{1}$$

$$(1)^3: 1 \le n^3$$
 (2)

$$(2) \cdot 7: \quad 7 \le 7n^3 \tag{3}$$

$$(1) \cdot 2n^2 : \quad 2n^2 \le 2n^3 \tag{4}$$

$$3n^3 \le 3n^3 \tag{5}$$

$$(3) + (4) + (5) : 3n^3 + 2n^2 + 7 \le 12n^3$$
 (6)

Durch die Ungleichungen (3), (4) und (5) ist für jedes Polynom einzeln eine Abschätzung erfolgt. Addiert man diese Ungleichungen nun, ergibt sich (6). Damit ist gezeigt, dass die Behauptung wahr ist und die Funktion in  $O(n^3)$  liegt. Aus der Definition der O-Notation ergibt sich, dass jede Funktion mit höchstem Grad 3 in  $O(n^3)$  liegt, da Vorfaktoren und Konstantglieder entfallen.

Die O-Notation eines Algorithmus lässt sich auch durch vollständige Induktion beweisen.

Beispiel 2. Behauptung:  $n \in O(2^n)$ 

Beweis. Wähle  $n_0 := 0, c := 1$ . Zu zeigen:  $n \leq 2^n \forall n \in \mathbb{N}$ 

Beweis durch Induktion nach n:

Induktionsanfang (IA): n = 0  $n = 0 \le 1 = 2^0 = 2^n$ Induktionsvoraussetzung (IV):  $n \le 2^n$  z.Z.  $n + 1 \le 2^{n+1}$ 

 $<sup>^1</sup>$ Die Wahl von c und n erfolgt hier durch Ausprobieren – In diesem Fall ergibt sich 12 als Summe aus den Potenzfaktoren.

Induktionsschritt (IS):  $n \mapsto n+1$ 

Per einfacher Induktion kann man nun zeigen:

$$n \le 2^n \tag{7}$$

Daraus folgt mit IV: 
$$n+1 \le 2^n + 2^n = 2 * 2^n = 2^{n+1}$$
 (8)

Die Eigenschaft  $f \in O(g)$  induktiv zu zeigen, ist mühsam. Stattdessen können die folgenden Propositionen genutzt werden:

#### Bemerkung 3.

$$f \in O(f) \tag{9}$$

$$f \in O(g) \Rightarrow d \cdot f \in O(g)$$
 (10)

$$f \in O(n) \land g \in O(n) \Rightarrow f + g \in O(n)$$
 (11)

$$f_1 \in O(g_1) \land f_2 \in O(g_2) \Rightarrow f_1 \cdot f_2 \in O(g_1 \cdot g_2)$$
 (12)

$$f_1 \in O(g_1) \land f_2 \in O(g_2) \Rightarrow \frac{f_1}{f_2} \in O(\frac{g_1}{g_2})$$
 (13)

$$f \in O(g) \land g \in O(n) \Rightarrow f \in O(n)$$
 (14)

Darüber hinaus gilt folgender Satz:

**Satz 1.** Seien  $f, g : \mathbb{N} \to \mathbb{R}_+$ . Dann gilt:

$$f(n) \in O(g(n)) \iff (\frac{f(n)}{g(n)})_{n \in \mathbb{N}} \text{ ist beschränkt}$$

Außerdem finden Grenzwertbetrachtungen Eingang:

## Lemma 1.

$$f \in O(g) \text{ und } g \in O(f), \text{ wenn } \lim_{n \to \infty} \left(\frac{f(n)}{g(n)}\right) = c, c \neq 0$$
 (15)

$$f \in O(g) \text{ und } g \notin O(f), \text{ wenn } \lim_{n \to \infty} \left(\frac{f(n)}{g(n)}\right) = 0$$
 (16)

$$f \notin O(g) \text{ und } g \in O(f), \text{ wenn } \lim_{n \to \infty} \left(\frac{f(n)}{g(n)}\right) = \infty$$
 (17)

Neben der O-Notation gibt es zwei weitere Notationen, die im Folgenden vorgestellt werden.

## **3.1.** $\Omega$ -Notation

Neben der Menge aller Funktionen, die höchstens so schnell wächst wie die betrachtete Funktion, bezeichnen wir die Menge der Funktionen, die mindestens so schnell wächst wie die Funktion als  $\Omega(n)$ .

**Definition 5.** Sei  $g \in \mathbb{R}_+$ . Die Menge aller Funktionen, die mindestens so schnell wachsen wie g ist:

$$\Omega(n) := \{ f \in \mathbb{R}_+^{\mathbb{N}} \mid \exists n_0 \in \mathbb{N} : \exists c \in \mathbb{R}_+ : \forall n \in \mathbb{N} : (n \ge n_0 \Rightarrow F(n) \ge c \cdot g(n)) \}$$

Diese Notation fristet ein Schattendasein: In der Regel ist die O-Notation geeigneter, da eine Orientierung am "Worst-Case-Szenario" üblicher ist.

#### 3.2. $\Theta$ -Notation

Aus O-Notation und  $\Omega$ -Notation ergibt sich nun die Menge der Funktionen, die genau so schnell wachsen wie die betrachtete Funktion. Wir bezeichnen sie mit  $\Theta$ .

Definition 6.

$$\Theta(g) = O(g) \cap \Omega(g)$$

## 3.3. Zusammenfassung

- Die O-Notation umfasst alle Funktionen, die nicht schneller wachsen als f. Damit beschreiben wir eine obere Schranke für die Komplexitätsfunktion.
- Die  $\Omega$ -Notation umfasst alle Funktionen, die mindestens so schnell wachsen wie f. Dies ist eine untere Schranke.
- Die  $\Theta$ -Notation umfasst alle Funktionen, die genau so schnell wachsen wie f. Damit erhalten wir ein asymptotisches Maß.

**Lemma 2.** •  $f \in O(g)$  und  $g \in O(f)$ , also  $f \in O(g)$  und  $f \in \Omega(g)$ , wenn  $\lim_{n \to \infty} \frac{f(n)}{g(n)} = c, c \neq 0$ , also:  $f \in \Theta(g)$ 

• 
$$f \in O(g)$$
 und  $g \notin O(f)$ , wenn  $\lim_{n \to \infty} \frac{f(n)}{g(n)} = 0$ , also:  $g \in \Omega(f)$  und  $f \notin \Omega(g)$ 

• 
$$f \notin O(g)$$
 und  $g \in O(f)$ , also  $g \notin \Omega(f)$  und  $f \in \Omega(g)$ , wenn  $\lim_{n \to \infty} \frac{f(n)}{g(n)} = \infty$ 

# 4. Rekursionsgleichungen

Nun haben wir mit den Landau-Symbolen einen mathematischen Weg gefunden, die Komplexität von Algorithmen zu beschreiben. Im Folgenden wenden wir dieses Modell auf konkrete Algorithmen an.

Bekannte Algorithmen sind beispielsweise Such- oder Sortierverfahren. Diese sind häufig rekursiv, d.h. eine Iteration verarbeitet direkt das Ergebnis einer vorherigen. Dadurch ergeben sich nun sogenannte **Rekurrenzgleichungen** oder auch **Rekursionsgleichungen**.

**Beispiel 3.**  $T(n) = 2 \cdot T(n-1) + 1$  ist eine Rekurrenzgleichung, da der Funktionswert n-1 direkt vom Funktionswert n-1 abhängt. Aus den Programmierkonzepten ist uns Rekursion als ein "Wiederaufruf von sich selbst" bekannt, dieses Muster findet sich hier in unseren betrachteten Algorithmen.

Um die Komplexität eines rekursiven Algorithmus bestimmen zu können, bedienen wir uns je nach Rekursionsgleichung unterschiedlichen Verfahren. Eines davon ist das sogenannte Mastertheorem.

#### 4.1. Mastertheorem

Satz 2. Sofern alle Teilprobleme die gleiche Größe haben, können wir zwei Fälle unterscheiden:

• Basisfall: f(n) ist konstant für hinreichend kleine Werte von n

• Für größere n lässt sich eine Rekursionsgleichung der folgenden Form bestimmen:

$$f(n) = a \cdot f(\frac{n}{b}) + O(n^d)$$

a ist hier die Anzahl der rekursiven Aufrufe, b der Verkleinerungsfaktor des Problems und d der Exponent für die Laufzeit der Vorbereitung der Rekursion und/oder die Zusammensetzung der Teilprobleme.

Nun gilt Folgendes:

$$f(n) \in \begin{cases} O(n^d) & \text{falls } a < b^d \\ O(n^d \cdot \log_b(n)) & \text{falls } a = b^d \\ O(n^{\log_b(a)}) & \text{falls } a > b^d \end{cases}$$

Mithilfe dieses Theorems kann nun die Komplexität eines rekursiven Algorithmus bestimmt werden:

Beispiel 4. Gegegeben sei

$$f(n) = 2 \cdot f(\frac{n}{2}) + O(n^2)$$

Daraus folgt a = 2, b = 2, d = 2.

Da  $2 < 2^2$  trifft der erste Fall ein und wir halten fest:  $f(n) \in O(n^2)$ .

Über das Mastertheorem sind eine Zahl an Rekursionsgleichungen entscheidbar, jedoch nicht jede. Für die Rekursionsgleichungen, deren Form nicht der für das Mastertheorem benötigten entspricht, werden andere Verfahren nötig.

## 4.2. Auflösungsverfahren

Eine gegebene Rekursionsgleichung lässt sich in eine geschlossene Form überführen, in der keine Abhängigkeit zu vorherigen Funktionswerten mehr besteht. Dafür existieren zwei Ansätze:

- bottom-up: Aus berechneten Funktionswerten für kleine n wird eine weitere Berechnungsvorschrift ermittelt. Diese muss anschließend induktiv bewiesen werden.
- top-down: Die vorherigen Funktionswerte werden solange durch die entsprechende Gleichung ersetzt, bis der definierte Startwert eingesetzt werden kann. Anschließend wird der Term zusammengefasst und es ergibt sich eine geschlossene Rechenvorschrift.

**Beispiel 5.** Gegeben ist die folgende Rekursionsgleichung: f(1) = 1,  $f(n) = 2 \cdot f(n-1) + 1$ .

bottom-up

$$f(1) = 1 \tag{18}$$

$$f(2) = 2 \cdot 1 + 1 = 3 \tag{19}$$

$$f(3) = 2 \cdot 3 + 1 = 7 \tag{20}$$

$$f(4) = 2 \cdot 7 + 1 = 15 \tag{21}$$

Aus den Ergebnissen wird relativ schnell eine Verwandtschaft zu den ersten Potenzen der Zahl 2 deutlich und so lässt sich nun folgende Gleichung aufstellen:

$$f(n) = 2^n - 1$$

Diese Gleichung kann nun für die gegebenen Werte von n überprüft werden und muss anschließend (induktiv) bewiesen werden.

Beweis. Zu zeigen:  $f(n) = 2 \cdot f(n-1) + 1 \in O(2^n)$ 

Induktionshypothese:  $f(n) = 2^n - 1 \quad \forall n \ge 1$ 

Induktionsanfang:  $f(1) = 2^1 - 1 = 1$ 

Induktionsvoraussetzung:  $n \to n+1$   $f(n+1) = 2^{n+1} - 1$ 

Induktionsschritt:  $f(n+1) = 2 \cdot f(n) + 1 = 2 \cdot (2^n - 1) + 1 = 2^{n+1} - 1$ 

nach 
$$[Jan03]$$

Wir führen Induktionsbeweise für Rekurrenzgleichungen, indem wir zunächst im Induktionsanfang feststellen, dass unsere ermittelte Funktion den Rekursionsstartwert erfüllt. Ist dies nicht der Fall, brechen wir hier ab. Nun induzieren wir, in dem wir n auf n+1 abbilden, bilden die Rekursionsgleichung für n+1 und setzen nun für f(n) unsere geschlossene Funktion ein. Wir stellen fest, dass unsere Induktionsvoraussetzung erfüllt ist. Damit ist unsere Auflösung der Rekursionsgleichung gezeigt.

#### top-down

$$f(n) = 2 \cdot f(n-1) + 1 \tag{22}$$

$$= 2 \cdot (2 \cdot f(n-2) + 1) + 1 \tag{23}$$

$$= 2 \cdot (2 \cdot (\dots \cdot (2 \cdot 1) + 1) \dots) + 1) + 1 \tag{24}$$

$$\Rightarrow 2^{n-1} + 2^{n-2} + \dots + 2^{n-(n-1)} + 1 \tag{25}$$

$$= \sum_{i=0}^{n-1} 2^i = \frac{2^{(n-1)+1} - 1}{2-1} = 2^n - 1 \in O(2^n)$$
 (26)

Je nach Rekursionsgleichung bietet sich mitunter eines der beiden Verfahren mehr an als das andere. Vernachlässigt werden darf beim bottum-up-Verfahren nicht, dass ein Induktionsbeweis erforderlich ist! Bei Rekursionsgleichungen mit zweifacher Rekursion (in Beziehung zu den vorherigen zwei Funktionswerten) ist ein top-down-Verfahren deutlich komplexer und häufig nicht ratsam.

# **Aufgaben**

**Aufgabe 1** Veranschaulichen Sie die O-,  $\Theta$ - und  $\Omega$ -Notation anhand der Funktion  $f(n) = 3n^3 + 7n^2 + 16$  grafisch.

Lösung auf Seite 53

Aufgabe 2 Geben Sie zu folgenden Funktionen jeweils die O-Notation an.

- 1.  $f(n) = 6n^4 + 3 \cdot log_2(n)$
- 2. f(n) = 6627816n + 13
- 3.  $f(n) = \frac{72n^3 + 27n^2 + 8n + 9}{n!}$
- 4.  $f(n) = 3n \cdot \frac{n!}{2} + n^n$

Lösung auf Seite 53

## Aufgabe 3

- 1. Zeigen Sie, dass  $n^2 \in O(2^n)$ .
- 2. Zeigen Sie, dass  $n^3 \in O(2^n)$ .

Lösung auf Seite 54 entnommen aus VL

**Aufgabe 4** Bestimmen Sie unter Anwendung des Mastertheorems die jeweilige Komplexitätsklasse O(n).

- $f(n) = 2 \cdot f(\frac{n}{2n+1}) + n^2$
- $g(n) = log(n) \cdot g(\frac{n}{2}) + 3$
- $h(n) = sin(n) \cdot h(\frac{n}{\frac{n}{2}}) + O(n^3)$

Lösung auf Seite 54

**Hinweis** Für einige Aufgaben kann es hilfreich sein, die Tabelle der Komplexitätsklassen auf Seite 13 zu verwenden. Im Rahmen der Klausurvorbereitung sollten Sie außerdem die Komplexität von Algorithmen aus Pseudocode heraus angeben können.

# 5. Bestimmung von Komplexitäten

Nun haben wir in ausreichender Tiefe mathematisch-formal die O-Notation als Maß der Komplexität eingeführt. In der Praxis – und insbesondere auch in Klausuren – ist davon auszugehen, dass Sie einen Algorithmus in einer Programmiersprache implementiert oder als Pseudocode erhalten, zudem Sie dann aus dem Code heraus die Komplexität bestimmen sollen.

Dies wollen wir hier näher erläutern und üben.

## 5.1. Rechengesetze der *O*-Notation

**Satz 3.** Seien  $d \in \mathbb{R}_{>0}$  und  $f, g, h : \mathbb{N}_0 \to \mathbb{R}_{>0}$ , dann gilt:

$$d = O(1) \tag{27}$$

$$f = O(f) \tag{28}$$

$$d \cdot f = O(f) \tag{29}$$

$$f + g = O(g), \text{ falls } f = O(g)$$
(30)

$$f + g = O(\max\{f, g\}) \tag{31}$$

$$f \cdot g = O(f \cdot h), \text{ falls } g = O(h)$$
 (32)

Quelle: [WM20, S. 67]

Mithilfe dieser Rechengesetze können wir O-Notationen leichter bestimmen. Sie sind die Grundlage für Vereinfachungen, die Vergleiche der Komplexität im Ende ermöglichen.

#### 5.2. Komplexitätsklassen

Betrachten wir nun allgemein die häufigsten Komplexitätsklassen, mit denen sich bereits viele Algorithmen vergleichen lassen. Dabei sind jeweils Klassen angegeben, d.h. beispielsweise  $n^4$  läge zwischen  $n^3$  und  $2^n$  und fällt hier in die Klasse der kubischen Komplexitäten. Aus dieser Tabelle und den vorangegangenen Rechengesetzen lässt sich nun beispielsweise auch die Komplexität einer zusammengesetzten Funktion wie beispielsweise  $f(n) = n^3 + n!$  bestimmen. Da n! um ein wesentliches schneller wächst als  $n^3$ , fällt f in die Komplexitätsklasse n!. Nun ergibt sich die Frage, wie wir einen gegebenen Algorithmus nun einer

Klasse	Bezeichnung	Rang
O(1)	konstant	exzellent
$O(log_x(n)$	logarithmisch	sehr gut
O(n)	linear	gut
$O(n \cdot log(n))$	überlinear	gut
$O(n^2)$	quadratisch	eher ineffizient
$O(n^3)$	kubisch	ineffizient
$O(2^n)$	exponentiell	sehr ineffizient
O(n!)	faktoriell	extrem ineffizient

Tabelle 1: Komplexitätsklassen nach [ESB16]

dieser Klassen zuordnen, ohne, dass bereits vorher eine Funktionsgleichung gegeben ist. Dafür können wir diese Tabelle nutzen, die aufschlüsselt, wo die jeweilige Komplexität in Algorithmen vorkommt.

Klasse	Typischer Aufbau eines Algorithmus dieser Komplexität
O(1)	die meisten Anweisungen werden nur einmal oder konstant
	oft ausgeführt (unabhängig von Eingaben)
O(log(n)	Lösen eine Problems durch Aufteilen in kleinere Teilproble-
	me, dabei wird die Laufzeit um einen konstanten Anteil ver-
	ringert
O(n)	Falls $n$ Eingabedaten verarbeitet werden müssen, ist dies der
	optimale Fall, da jedes Element nur einmal bearbeitet wird
$O(n \cdot log(n))$	Lösen eines Problems durch Aufteilen in kleinere Probleme,
	die unabhängig voneinander gelöst und abschließend rekom-
	biniert werden
$O(n^2)$	typisch für die paarweise Verarbeitung von $n$ Elementen $\rightarrow$
	zwei verschachtelte For-Schleifen
$O(n^3)$	drei verschachtelte For-Schleifen
$O(a^n)$	Brute-Force-Lösungen (Ausprobieren aller Optionen)

Tabelle 2: Zuordnung von Algorithmen zu Verarbeitungsschritten nach [ESB16, S. 436]

## 5.3. Komplexität von Programmierkonzepten

Eine einzelne Anweisung hat immer die Komplexität O(1). Auch mehrere Anweisungen – deren Anzahl jedoch nicht von der Menge der Eingabedaten n abhängt – verändern die Komplexität nicht.

**Schleifen** Sofern jedoch eine Schleife in Abhängigkeit von n (auch hier müssen nicht exakt n Schleifendurchläufe passieren, es genügt eine generelle Abhängigkeit!) durchlaufen wird, erhalten wir einen Aufwand von O(n) mit n = Anzahl der Daten.

Betrachten wir nun ineinander verschachtelte Schleifen, deren Durchlaufanzahl jeweils von n abhängt, so multiplizieren sich die Komplexitäten und wir erhalten beispielsweise für zwei ineinander verschachtelte For-Schleifen eine Komplexität von  $O(n^2)$ . Nach diesem Muster gehen wir für beliebig häufig ineinander verschachtelte Schleifen vor.

Beispiel 6. Gegeben sei folgender Algorithmus:

```
\begin{array}{lll} \textit{public} & \textit{void} & \textit{validateInput(int[] data)} \ \\ & \textit{int} & \textit{i} = \textit{0}; \\ & \textit{for} & (\textit{dataElement in data}) \ \\ & & \textit{calculateSomething(dataElement)}; \\ & & \textit{while} & (\textit{i} < \textit{10}) \ \\ & & & \textit{pingHost('localhost:3000/')}; \\ & & & \textit{i} + +; \\ & & & & \\ \} \end{array}
```

Wir betrachten zur Bestimmung der Komplexität:

- int i = 0 ist eine einzelne Anweisung ohne Abhängigkeit zu n, hat also die Komplexität O(1).
- Nun beginnt eine For-Schleife mit n (= Anzahl der Feldelemente) Iterationen, also mit Komplexität O(n).

- Innerhalb der For-Schleife findet pro Iteration ein Aufruf der Funktion calculateSomething statt, deren Komplexität in derer der Schleife bereits inbegriffen ist (da es sich um einen einzelnen Aufruf pro Iteration handelt).
- Nun beginnt eine weitere Schleife deren Iterationsanzahl jedoch von n unabhängig ist und konstant 10 beträgt. Auch der Inhalt der Schleifen ist konstant und fällt daher nicht ins Gewicht. Daher beträgt die Komplexität hier erneut O(1). Da wir Klassen von Komplexität betrachten, ist O(10) zwar nicht falsch, jedoch nicht sinnvoll, weil so die Vergleichbarkeit entfällt/erschwert wird.
- Auch i++ ist eine Anweisung mit konstantem Zeitbedarf, also O(1).

Nun addieren wir die einzelnen Komplexitäten und erhalten O(n), da konstante Terme entfallen.

**Satz 4.** Eine Schleife, in der die Datenmenge in jeder Iteration halbiert wird, hat eine Komplexität von  $O(\log(n))$ .

Neben Schleifen, deren Komplexitätsbetrachtung wir nun in aller Ausführlichkeit ausgeführt haben, widmen wir uns nun einem weiteren, in Algorithmen sehr häufig anzutreffenden Programmierkonzept:

**Rekursion** Die Komplexität von rekursiven Algorithmen zu bestimmen ist im Allgemeinen aufwendiger. Wir betrachten verschiedene Fälle:

- Falls in jedem Schritt die betrachtete Datenmenge um eins kürzer wird und die zusätzlich ausgeführte Operation einen konstanten Zeitbedarf hat, so liegt die Komplexität in O(n).
- Ist dieser Zufallsaufwand nun nicht konstant sondern linear (verändert sich also in Abhängigkeit von n, so verändert sich der Aufwand und wir erhalten eine Komplexität von  $O(\frac{n^2}{2})$ .

An dieser Stelle sei auch noch einmal auf das **Master-Theorem** verwiesen, das bei Rekursionsgleichungen Anwendung findet, die gemäß "Divide and Conquer" (Teile und Herrsche) Probleme in kleinere Teilprobleme zerteilen, diese getrennt voneinander verarbeiten und anschließend wieder zusammensetzen. ( $\rightarrow$  Mergesort, S. 28)

# Aufgaben

- Gegeben sind die folgenden Pseudocode-Darstellungen verschiedener Algorithmen.
- Notieren Sie zu jeder Anweisung die entsprechende Komplexität.
- Geben Sie die Gesamtkomplexitätsklasse des Algorithmus in Landau-Symbolen an.

Verwenden Sie falls erforderlich das Master-Theorem.

## Aufgabe 1

```
public int[] giveEvenNumbers(int[] data) {
    int[] result;
    for (dataElement in data) {
        if (dataElement % 2 == 0) {
            result.append(dataElement);
        }
    }
    return result;
}
```

Lösung auf Seite 55

#### Aufgabe 2

Lösung auf Seite 55 entnommen aus [Sch19]

### Aufgabe 3

Lösung auf Seite 55 entnommen aus [Sch19]

# Teil II.

# Suchalgorithmen

Sie studieren Informatik, sind es satt, noch mehr Stunden vor Bildschirmen zu verbringen und suchen sich deshalb ein echtes, physisches Buch aus der Bibliothek Ihrer Hochschule heraus. Sie fragten nach "WIRTH: Algorithmen und Datenstrukturen" von 1983, weil man es Ihnen in Ihrer Vorlesung empfahl. Die Bibliothekarin deutet auf ein Regal und lässt sie damit allein.

Wie finden Sie das gesuchte Buch in der Regalreihe mit etwa 300 Büchern?

### 6. Lineare Suche

Sie beginnen ganz links. Nun lesen Sie den Titel des ersten Buches, er passt nicht. Sie lesen den Titel des zweiten Buches, er passt ebenfalls nicht. Sie fahren fort, iterieren über das gesamte Bücherregal und brechen ab, falls Sie es gefunden haben oder am Ende angelangt sind. Dieses Verfahren ist die **Lineare Suche**.

**Idee** Durchlaufe sukzessive das Feld A, bis das gesuchte Element gefunden ist bzw. das Ende des Feldes erreicht ist.

**Komplexität** Ganz offensichtlich ist der Aufwand dieses Suchverfahrens durch die Feldlänge (also die Anzahl der Bücher in unserem Regal) bestimmt.

günstigster Fall Das gewünschte Element steht an Indexposition 0 (also dem ersten Element bzw. es ist das erste Buch im Regal)  $\rightarrow$  ein Vergleich ist erforderlich

durchschnittlicher Fall Das gewünschte Element steht an der mittleren Indexposition  $\frac{n}{2}$  bei n Feldelementen.  $\rightarrow \frac{n}{2}$  Vergleiche sind erforderlich

ungünstigster Fall Das gewünschte Element ist nicht im Feld vorhanden.  $\rightarrow n$  Vergleiche

Insgesamt ergibt sich – da wir bei der Angabe der Komplexität durch die O-Notation jeweils den ungünstigsten Fall betrachten – für die Lineare Suche eine Komplexität von O(n).

## 7. Binäre Suche

Sie befinden sich in der perfekten Bibliothek: Alle Bücher sind aufsteigend nach ihren Autor\*innen sortiert! Dieses Wissen können Sie sich zunutze machen, in dem Sie ihr Wunschbuch mit der binären Suche finden: Sie teilen die Bücherreihe in zwei Hälften und betrachten nun das mittlere Buch: Muss Ihr Buch links oder rechts von dem mittleren Buch stehen (Vergleich anhand des Namens der Autoren)? Oder ist es sogar ihr Buch? Nein, das ist es nicht und der Autor Ihres Buches hat einen im Alphabet weiter hinten stehenden Anfangsbuchstaben, also betrachten Sie die Hälfte rechts des mittleren Buches. Diese Hälfte teilen Sie nun erneut, betrachten die neue Mitte und fahren fort, bis ihre Hälften aus einem Buch bestehen.

**Idee** Vergleiche zu suchendes Element E mit der Mitte des Suchbereiches A[m]. Falls gefunden: Abbruch. Falls E < A[m]: Suche weiter in linker Hälfte. Falls E > A[m]: Suche weiter in rechter Hälfte. Das Weitersuchen erfolgt durch einen rekursiven Aufruf des Algorithmus mit der entsprechenden Hälfte des Feldes.

```
BinarySearch(A[], E, indexLeft, indexRight) {
        if (indexLeft > indexRight) {
            return ElementNotFound
        }
        else {
            mid = (indexLeft+indexRight) / 2;
            if (E == A[mid]) {
                return mid;
            }
            else if (E < A[mid] {
                      return BinarySearch(A[], E, indexLeft, mid-1);
            }
            else {
                      return BinarySearch(A[], E, mid+1, indexRight);
            }
        }
}</pre>
```

Die Parameter indexLeft und indexRight schränken jeweils das zu betrachtende Feld ein. Zu Beginn ist indexLeft mit 0 und indexRight mit A[].length() initialisiert.

Komplexität Hier handelt es sich um ein rekursives Verfahren, folglich werden wir eine Rekursionsgleichung erhalten und diese mit den bekannten Verfahren auswerten. Doch zunächst betrachten wir wieder Fälle:

```
günstigster Fall: E ist das mittlere Element \to 1 Vergleich ungünstigster Fall: E ist nicht im Feld
```

Die Rekursionsgleichung mit den Parametern a, bundd ergibt sich nun wie folgt:

- Es gibt einen rekursiven Aufruf, d.h. a = 1.
- Pro Rekursionsaufruf halbieren wir das Feld, daraus folgt b=2.
- Die Vorbereitung der Rekursion verläuft konstant und ist minimal, also d=1.

Die Rekursionsgleichung lautet nun:

$$f(n) = 1 \cdot f(\frac{n}{2}) + 1$$

Für die Anwendung des Mastertheorems formen wir um:

$$\iff f(n) = 1 \cdot f(\frac{n}{2}) + O(n^0)$$

Nun ergibt sich:

$$a = b^d \iff 1 = 2^0 \Rightarrow f(n) \in O(n^0 \cdot log_2(n)) = O(log(n))$$

#### 8. Textsuche

Spätestens jetzt sollten Sie das Buch gefunden haben, wenn Sie die binäre Suche verwendet haben, vermutlich schneller als mit der linearen Suche. Jetzt haben Sie einen Arbeitsplatz gefunden, setzen sich und schlagen das Buch auf: Für ein Lesen in Ruhe haben Sie keine Zeit, daher suchen Sie sich die interessanten Teile heraus. Sie suchen, wo NIKLAUS WIRTH Ihnen die O-Notation erklären wird.

Formal suchen Sie folglich alle Vorkommen eines Musters (in Form einer Zeichenkette) in einem Text. Dafür betrachten wir zwei Verfahren.

#### 8.1. Einfache Textsuche

Analog zur linearen Suche beginnen Sie einfach, Ihren gesuchten Begriff unter den Text zu legen. Stimmt der erste Buchstabe überein, vergleichen Sie den zweiten. Stellen Sie eine Differenz fest, verschieben Sie Ihr Suchwort um eine Position nach rechts. Derart fahren Sie fort, bis Sie am Ende des Textes angelangt sind.

**Idee** Beginnend beim ersten Zeichen des Textes legt man das Muster der Reihe nach an jede Stelle des Textes an und vergleicht zeichenweise von links nach rechts, ob eine Übereinstimmung vorliegt

**Komplexität** Offenbar hängt der Aufwand dieses Verfahrens ganz wesentlich davon ab, wie lang das Muster und der Text in Gänze sind. Weniger relevant hingegen ist der Aufbau des Textes, da alle Vorkommen des Musters gesucht werden. Insofern ist es nicht entscheidend, an welcher Stelle das Muster das erste Mal auftritt.

günstigster Fall Im günstigsten Fall werden m<br/> Vergleiche benötigt, wenn nämlich die Länge des Textes kleiner als das doppelte der Länge des Muster<br/>smist und das Muster direkt am Beginn des Textes steht. <br/>  $\rightarrow m$  Vergleiche

ungünstigster Fall Im ungünstigsten Fall werden  $(n-m+1)\cdot m$  Vergleiche benötigt, wobei dieser Fall allgemeingültig ist – es werden alle Vorkommen des Musters im Text gesucht und nicht lediglich das erste.

Die Laufzeit des Algorithmus liegt nun in  $O(n \cdot m)$ .

## 8.2. Knuth-Morris-Pratt-Algorithmus (KMP)

Ihnen ist das zu mühsam geworden, Zeichen für Zeichen des Textes und des Musters zu vergleichen. Sie sehnen sich nach einem intelligenteren, einfacheren Weg. Und, wahrlich den gibt es: Der **Knuth-Morris-Pratt**-Suchalogorithmus nach Donald Ervin Knuth, James Hiram Morris und Vaughan Ronald Pratt.

Die Grundlage für diesen Algorithmus bildet die vorangegangene einfache Textsuche. Diese optimieren wir nun, in dem wir beim ersten sich unterscheidenden Zeichen von Text und Muster das Muster nicht um ein einziges Zeichen nach rechts verschieben, sondern um eine bestimmte Anzahl an Zeichen, die sich aus unserem Muster ergibt und als Rand bezeichnet wird.

**Definition 7.** Der Rand eines Musters M mit der Länge m ist eine tabellarische Auflistung aller Teilzeichenketten der Längen 0 bis m des Musters, für die jeweils die Anzahl der Zeichen eines Prefixes, das zugleich Postfix ist, bestimmt wird.

Beispiel 7. Betrachten wir das Wort abbababab. Wir beginnen eine tabellarische Auflistung:

Teilzeichenkette	Länge	Rand	Bemerkung
	0	-1	per Definition, für Teilschritt 2 (Suche) erforderlich
a	1	0	per Definition
ab	2	0	$a \neq b$
abb	3	0	
abba	4	0	$ab \neq ba$ , Palindrome haben den Rand 0
abbab	5	2	gleich: ab, Länge: 2
abbaba	6	1	gleich: a, Länge: 1
abbabab	$\gamma$	2	gleich: ab, Länge: 2
abbababb	8	3	gleich: abb, Länge: 3
abbababba	9	4	gleich: abba, Länge: 4
abbababbab	10	5	gleich: abbab, Länge: 5

Im folgenden Suchalgorithmus wird jeweils der Rand verwendet, um Verschiebungspositionen zu bestimmen. Daher ist die gesamte Tabelle erforderlich.

Implementierung als Pseudo-Code

Folglich iterieren wir nun über alle möglichen Teilzeichenkettenlängen (j) und vergleichen jeweils mit dem vorherigen Rand (durch i). Wenn unser Rand maximal ist, verlassen wir die while-Schleife und speichern den ermittelten Rand.

Eine Veranschaulichung der algorithmischen Rand-Bestimmung finden Sie in der Wikipedia. [Wik20]

Der Suchalgorithmus Ahnlich wie bei der einfachen Textsuche beginnen Sie, indem Sie das zu suchende Muster unter den Suchraum schreiben und vergleichen Zeichen für Zeichen. Entscheidend ist nun die erste Abweichung: Sie bestimmen den Rand [] der Indexposition der Abweichung im Muster und verschieben ihr Muster nun mit unterer Formel. So nutzen Sie aus, dass bis zur ersten Abweichung Gleichheit bestand – falls bei vier gleichen Zeichen ein Rand von zwei vorliegt, können Sie ihr Muster so verschieben, dass der Beginn nun dort liegt, wo zuvor das mit dem neuen Anfang identische Enge lag. Nun fahren Sie mit den neu gewonnen Index-Positionen fort, die sich aus dem Verschiebung ergeben haben.

Die Formel für Verschiebungen ist:

Neuer Beginn des Musters (neue Suchtextposition) = Suchtextposition (aktueller Beginn des Musters) + (Anzahl übereinstimmender Zeichen -- Randlänge)

Beispiel 8. Sie suchen das Muster ababaab im Text baabbaabababbabba. Schritt 1: Bestimmung des Randes

Schritt 2: Suche

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
b	a	a	b	b	a	a	b	a	b	a	a	b	b	b	a	b	b	a
a	b	a	b	a	a	b												

Erste Abweichung an Index  $0 \to Rand[0] = -1$ , nach Formel oben: 0 + (0 - (-1)) = 1. Also verschieben wir das Muster an Indexposition 1.

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
b	a	a	b	b	a	a	b	a	b	a	a	b	b	b	a	b	b	a
	a	b	a	b	a	a	b											

Abweichung an Index 2, Rand[2] = 0, mit Formel: 1 + (1 - 0) = 2. Wir verschieben also so, dass das erste Zeichen des Musters an Index 2 steht.

0	1	2	3	4	5	6	$\gamma$	8	9	10	11	12	13	14	15	16	17	18
b	a	a	b	b	a	a	b	a	b	a	a	b	b	b	a	b	b	a
		a	b	a	b	a	a	b										

Abweichung an Index 4, Rand[2] = 0, mit Formel: 2 + (2 - 0) = 4. Neue Indexposition des Musters: 4.

0	1	2	3	4	5	6	$\gamma$	8	9	10	11	12	13	14	15	16	17	18
b	a	a	b	b	a	a	b	a	b	a	a	b	b	b	a	b	b	a
				a	b	a	b	a	a	b								

Abweichung an Index 4, Rand[0] = -1,  $mit\ Formel: 4 + (0 - (-1)) = 5$ . Neue Indexposition: 5.

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
b	a	a	b	b	a	a	b	a	b	a	a	b	b	b	a	b	b	a
					a	b	a	b	a	a	b							

Abweichung an Index 6, Rand[1] = 0, mit Formel: 5 + (1 - 0) = 6.

0	1	2	3	4	5	6	$\gamma$	8	9	10	11	12	13	14	15	16	17	18
b	a	a	b	b	a	a	b	a	b	a	a	b	b	b	a	b	b	a
						a	b	a	b	a	a	b						

Nun tritt keine Abweichung ein, das erste Vorkommen des Musters im Suchtext ist gefunden. Da wir nun an allen Vorkommen interessiert sind, führen wir unsere Suche fort. Dafür bestimmen wir zunächst den Rand[7] = 2. Mit der Formel folgt: 6 + (7 - 2) = 11. An Position 11 können wir nun unsere Suche fortsetzen.

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
b	a	a	b	b	a	a	b	a	b	a	a	b	b	b	a	b	b	a
											a	b	a	b	a	a	b	

11 + (2 - 0) = 13. Damit verlassen wir den Suchtext, der Algorithmus terminiert, da kein weiteres Vorkommen gefunden wurde.

Die Stärken des KMP-Algorithmus liegen folglich in der Berücksichtigung von Rändern an Anfang und Ende des Musters, die größere Sprünge als eins (im Vergleich zur einfachen Textsuche) ermöglichen. Liegt nun ein Muster ohne jegliche oder mit wenigen Rändern vor, ist der Laufzeitgewinn marginal.

#### Implementierung als Pseudo-Code

Wie ersichtlich ist, beginnen wir damit, unser Muster unter Anwendung der Ränder an die erste Position zu verschieben, an der das erste Zeichen übereinstimmt. Nun inkrementieren wir beide Zählervariablen und betrachten folgende Zeichen, in dem wir im nächsten Schleifendurchlauf bei Abweichungen weiterverschieben, bis die Länge des Musters erreicht wurde. Dann geben wir diese Indexposition aus und fahren fort.

**Komplexität** Da dieser Algorithmus aus zwei Teilproblemen besteht, zerfällt auch die Komplexität:

Das Bestimmen der Ränder erfolgt linear für das gesamte Muster, daraus folgt in Land-Au-Notation: Rand $(x) \in O(n)$  bei n als Länge des Musters. Der Suchalgorithmus selbst verläuft ebenfalls linear – insgesamt erfolgen maximal so viele Durchläufe wie der Text Zeichen enthält. Daraus folgt: KMPSearch $(x, y, R[]) \in O(m)$ 

Da beide Teilprobleme getrennt voneinander und aufeinander aufbauend durchlaufen werden, ergibt sich eine Komplexität des gesamten Algorithmus von O(n+m). [Wik20]

## 8.3. Boyer-Moore-Algorithmus

Ähnlich dem Ansatz von KNUTH, MORRIS und PRATT haben auch ROBERT S. BOYER und J STROTHER MOORE einen vergleichbaren Algorithmus zur effizienteren Suche von Zeichenketten in Texten entwickelt. Im Gegensatz zum KMP-Algorithmus werden dort keine Ränder bestimmt, sondern erst im Falle einer Abweichung greifen zwei Heuristiken: Die **Bad-character-** und **Good-suffix-**Heuristik, mithilfe derer ebenfalls Sprünge ermittelt werden. Dieses Verfahren hat eine Komplexität von  $O(n \cdot m)$  und ist damit im Allgemeinen (dem ungünstigsten Fall) weniger effizient als der KMP. Jedoch verläuft dieses Algorithmus nicht linear, sodass in einem günstigen Fall eine geringere Laufzeit erreicht werden kann.

Dieses Verfahren wird hier nicht näher dargestellt, da es nicht Teil der Vorlesung war. Weitere Informationen finden Sie bei  $[ESB16, S.\ 476-478]$ .

# **Aufgaben**

Aufgabe 1 Führen Sie eine binäre Suche nach dem Element 7 in [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 17, 18, 19, 22] durch. Notieren Sie jeweils Ihre Zwischenergebnisse.

Lösung auf Seite 56

Aufgabe 2 Bestimmen Sie die Ränder der folgenden Muster:

- OTTOSMOPSKOTZT
- ANANASBANANA
- BONOBO

Geben Sie jeweils an, wie sehr sich der Einsatz des KMP-Algorithmus bei diesen Mustern lohnt.

Lösung auf Seite 56

**Aufgabe 3** Wenden Sie den KMP-Algorithmus mit dem Muster BONOBO auf den Suchtext BEINAHEBOTNOCHDASBONOBONOBOHAUSPLATZ an. Stellen Sie Ihre Zwischenergebnisse dar.

Lösung auf Seite 56

Aufgabe 4 Erläutern Sie den Algorithmus der binären Suche in Ihren eigenen Worten.

Lösung auf Seite 56

# Teil III.

# Sortieralgorithmen

Nach langen, qualvollen Stunden vor dem Bücherregal hassen Sie ihr Leben, ihr Studium und Sie beschließen, es wegzuwerfen – Sie fangen in der Bibliothek als Fachkraft für Lagerlogistik an und sind nun für die korrekte Anordnung der Bücher im Regal verantwortlich. Auch hier zeigen Sie ihre geistige Brillianz, indem Sie das Problem des Sortierens auf abstrakter Ebene betrachten.

# 9. Allgemeines und Eigenschaften

**Definition 8.** Ein Sortieralgorithmus verarbeitet eine Folge von Elementen  $e_1, ..., e_n$  so, dass am Ende eine Ausgabe  $e_1, ..., e_n$  mit  $e_1 \le e_2 \le ... \le e_n$  erzeugt wird.

Als zugrunde liegende Datenstrukturen kommen Arrays, verkettete Listen oder weitere, spezielle Datenstrukturen mit zu Mengen/Relationen ähnlichem Aufbau infrage.

Da Sie bei Sortiervorgängen häufig Daten im key: value-Format betrachten, unterscheiden wir zwischen Schlüsseldaten (also den keys) und Satellitendaten (den zugehörigen Werten). So können wie beispielsweise Wetterdaten betrachten: [08.05.2021: 31.5, 09.05.2021, 30.2, 07.05.2021, 16.3] – Hier sind die Tage jeweils die Schlüsseldaten und die Temperaturangaben (die Gleitkommazahlen) jeweils Satellitendaten.

**Definition 9.** Ein Algorithmus sortiert Daten **stabil**, falls die Reihenfolge bereits sortierter Elemente mit gleichem Schlüssel nicht geändert wird und so insbesondere nach einem weiteren Kriterium sortierte Daten nach Ausführung des Algorithmus in diesem Kriterium ihre Sortierung beibehalten. Als **instabil** bezeichnen wir einen Sortieralgorithmus, falls das Gegenteil der Fall ist.

Ähnlich den Suchalgorithmen unterscheiden sich auch Sortieralgorithmen in weiteren Aspekten:

- Laufzeiteffizienz (→ LANDAU-Notation)
- Speicherplatzeffizienz
- Ablaufschema: Rekursiv oder Iterativ
- Stabilität der Daten

Für die Speicherplatzeffizienz ergibt sich folgende Unterscheidung:

**Definition 10.** Falls ein Sortieralgorithmus parallel zur Laufzeit keinen oder einen konstanten zusätzlichen Speicherbedarf benötigt, so wird er **in-place** ausgeführt. Ein Algorithmus, der hingegen zusätzlichen Speicherbedarf in Abhängigkeit zu den Daten benötigt, wird als **out-place** bezeichnet.

## 10. Insertion Sort

Der erste Sortieralgorithmus, den wir betrachten, heißt **Insertion Sort**. Wie der Name schon andeutet, geht es darum, Elemente einzufügen – in einen bestehenden, bereits sortierten Teil.

Sie beginnen links in Ihrer Bücherreihe, starten mit dem zweiten Buch. Sie prüfen nun, ob es im Vergleich zum ersten richtig steht, andernfalls tauschen sie es. Nun betrachten Sie das dritte Buch und fügen es vor/zwischen/nach Buch 1 und 2 ein, je nach richtiger Position. So fahren Sie fort: Sie fügen das jeweils aktuelle Buch in die Reihe der bereits sortierten ein.

#### Implementierung als Pseudo-Code

```
InsertionSort(Array) {
    int i = 0;
    while (i < (Array.length -1)) {
        x = Array[i];
        int y = 0;
        while (x < Array[i-y]) {
            y++;
        }
        Array[i-y] = x;
        i++;
    }
}</pre>
```

Beispiel 9. Zu sortieren Sie das Array [44, 55, 12, 42, 94, 18, 06, 67].

```
Ausgangswerte \\
                       55
                            12
                                 42
                                      94
                                           18
                                                06
                                                     67
                  44
                                 42
nach i = 1
                       55
                            12
                                                     67
                  44
                                      94
                                           18
                                                06
nach i = 2
                  12
                                 42
                                      94
                                           18
                                                06
                                                     67
                       44
nach i = 3
                  12
                                 55
                                           18
                       42
                            44
                                                06
                                                     67
nach i = 4
                  12
                       42
                                 55
                                      94
                                           18
                                                06
                                                     67
nach i = 5
                  12
                       18
                                           94
                                                06
                                                     67
                            42
                                 44
                                      55
nach i = 6
                  06
                       12
                            18
                                 42
                                           55
                                                94
                                                     67
                                      44
nach i = 7
                  06
                       12
                            18
                                 42
                                           55
                                                67
                                                     94
                                      44
```

Quelle: [ESB16, S. 493 ff.]

**Komplexität** Im günstigsten Fall operiert dieses Verfahren auf einem bereits sortierten Feld. Dann sind – um dies festzustellen – n-1 Vergleiche erforderlich. Im schlechtesten Fall ist das Feld in genau falscher Richtung sortiert: Dann sind  $\frac{n^2}{2}$  Vergleiche erforderlich, da die zweite Schleife auch maximal oft durchlaufen wird.

Insgesamt ergibt sich in Landau-Notation:  $\in O(n^2)$ 

## Eigenschaften

- Das Verfahren ist iterativ (erkennbar an den beiden Schleifen)
- Es ist stabil, da Vertauschungen nur im notwendigen Fall auftreten

• Das Verfahren operiert in-place, da kein bzw. nur konstanter zusätzlicher Speicher benötigt wird

Optimieren ließe sich das Verfahren durch den Einsatz von binärer Suche für die Einfügeposition – dann reduzieren sich die Vergleiche, nicht jedoch die Verschiebungen.

#### 11. Bubblesort

Mit **Bubble Sort** lernen wir einen weiteren Algorithmus zum Sortieren kennen: Hier vergleichen wir zunächst benachbarte Elemente und tauschen diese bei Bedarf. So durchlaufen wir das gesamte Array, bis keine Vertauschungen mehr notwendig sind und alle Elemente in der korrekten Reihenfolge angeordnet sind.

**Idee** Durchlaufe Feld mehrmals und tausche benachbarte Elemente bei Bedarf. Terminiere, wenn in einem Durchlauf keine Vertauschung mehr erfolgt ist.

```
Beispiel 10. Zu sortieren ist das Feld [6, 8, 2, 9, 1, 5, 4, 3]. 6 < 8, aber 8 > 2: [6, 2, 8, 9, 1, 5, 4, 3]. 8 < 9, aber 9 > 1: [6, 2, 8, 1, 9, 5, 4, 3] 9 > 5: [6, 2, 8, 1, 5, 4, 3] 9 > 4: [6, 2, 8, 1, 5, 4, 9, 3] 9 > 3: [6, 2, 8, 1, 5, 4, 3, 9]
```

#### Nächste Iteration:

```
6 > 2: [2, 6, 8, 1, 5, 4, 3, 9]
6 < 8, aber 8 > 1: [2, 6, 1, 8, 5, 4, 3, 9]
8 > 5: [2, 6, 1, 5, 8, 4, 3, 9]
8 > 4: [2, 6, 1, 5, 4, 8, 3, 9]
8 > 3: [2, 6, 1, 5, 4, 3, 8, 9]
8 < 9.
```

## Nächste Iteration:

```
2 < 6, aber 6 > 1: [2, 1, 6, 5, 4, 3, 8, 9]
6 > 5: [2, 1, 5, 6, 4, 3, 8, 9]
6 > 4: [2, 1, 5, 4, 6, 3, 8, 9]
6 > 3: [2, 1, 5, 4, 3, 6, 8, 9]
6 < 8 und 8 < 9.
```

#### Nächste Iteration:

```
2 > 1: [1, 2, 5, 4, 3, 6, 8, 9]
2 < 5, aber 5 > 4: [1, 2, 4, 5, 3, 6, 8, 9]
5 > 3: [1, 2, 4, 3, 5, 6, 8, 9]
5 < 6, 6 < 8 und 8 < 9.
```

#### Nächste Iteration:

```
1 < 2, 2 < 4, aber 4 > 3: [1, 2, 3, 4, 5, 6, 8, 9] 4 < 5, 5 < 6, 6 < 8 \text{ und } 8 < 9. Terminiert.
```

Aus dem Beispiel können wir ableiten, dass in jeder Iteration n-1 Vergleiche erfolgen. Dies ist ein Indiz für die Komplexität, die wir später betrachten möchten.

#### **Implementation** als Pseudo-Code

Die SwapFlag ist Terminationskriterium: Falls in einer Iteration kein Tausch mehr durchgeführt wurde, ist das Array vollständig sortiert.

**Komplexität** Im günstigsten Fall ist das Array bereits vollständig sortiert, dann werden n-1 Vergleiche notwendig. Im ungünstigsten Fall ist das Aray absteigend sortiert, nun sind  $\frac{n^2}{2}$  Vergleiche erforderlich.

Somit ergibt sich erneut eine Komplexität von  $O(n^2)$ .

Im Gegensatz zu ursprünglichen Implementierungen haben wir hier bereits eine Optimierung vorgenommen: Die SwapFlag bewirkt, dass im günstigsten Fall O(n) die passende Komplexitätsklasse ist.

#### Eigenschaften

- Auch Bubble Sort arbeitet offensichtlich iterativ.
- Bubble Sort ist ebenfalls stabil.
- Der Speicheraufwand ist in-place.

Quelle und weiterführende Literatur: [Wir83, S.86 ff.] [Vöc+08, S.22]

# 12. Mergesort

Die nächste Idee, wie Sie Ihr Bücherregal sortieren können: Mergesort! Sie teilen das Regal in zwei Hälften, sortieren jede Hälfte, in dem Sie diese wiederum halbieren, bis die Hälften aus einem Buch bestehen. Sortieren Sie diesen Teil, indem Sie die Bücher richtig anordnen und die Hälften so wieder von klein nach groß nach einer Art Reißverschlussprinzip verbinden, bis Sie die Gesamtheit der Elemente in sortierter Reihenfolge erhalten.

```
Beispiel 11. Zu sortieren: [1, 7, 6, 2, 9, 4, 3, 8, 10, 5].
Halbieren:
[1, 7, 6, 2, 9] | [4, 3, 8, 10, 5]
[1, 7, 6] [2, 9] | [4, 3, 8] [10, 5]
```

```
[1, 7][6][2][9] | [4, 3] [8][10][5]
[1][7][6][2][9] | [4][3][8][10][5]
Sortieren (nach rekursiven Aufrufen):
[1][2][6][7][9] | [3][4][5][8][10]
Merge:
[1] [2] [3] [4] [5] [6] [7] [8] [9] [10]
Implementierung als Pseudo-Code
MergeSort (Array) {
         if (Array.length \ll 1) {
                  return Array;
         }
         else {
                  leftHalf = MergeSort(Array[0:(Array.length - 2)]);
                  rightHalf = MergeSort(Array[(Array.length-a):-1]);
                  return merge(leftHalf, rightHalf);
         }
merge(A[], B[], al, ar, bl, br, C[]) {
         int i = al;
         int j = bl;
         for (int k = 0; k \le ar - al + br - bl + 1; k++) {
                  if (i > ar) {
                          C[k] = B[j+1];
                           continue;
                 if (j > br) {
                          C[k] = A[i+1];
                           continue;
                 C[k] = (A[i] < B[j] ? A[i++] : B[j++];
         }
```

**Komplexität** Für Mergesort ergibt sich – da es sich um einen rekursiven Algorithmus handelt – eine Rekursionsgleichung:

$$T(n) = T(\frac{n}{2}) + T(\frac{n}{2}) + n = 2T(\frac{n}{2}) + n$$

Jeder Rekursionsteil beschreibt die Komplexität der einzelnen Hälften und n das anschließende Zusammenfügen. Somit ergibt sich unter Anwendung des Mastertheorems eine Komplexität von

$$T(n) \in O(n \cdot log(n))$$

#### Eigenschaften

Quelle: [Vöc+08, S. 28]

- rekursiv
- stabil
- Je nach Implementierung in-place oder out-place

## 13. Quicksort

Willkommen in der Königksklasse: Quicksort trägt schon einen bezeichnenden, etwas anmaßenden Titel. Wir betrachten nun, ob der Algorithmus dem gerecht wird.

Idee Wir sortieren eine Menge an Elementen, in dem wir das erste Element p (das wir als **Pivot** bezeichnen) herausgreifen und nun unser Feld/Array so verschieben, dass alle kleineren Elemente ... < p links von p stehen und alle größeren rechts davon - wohlgemerkt noch nicht sortiert. Nun betrachten wir die neu gebildeten Abschnitte  $(a_0, ..., a_{p-1})$  und  $a_{p+1}, ..., a_n)$  und verfahren auf diesen Teilstapeln oder Teilmengen rekursiv. Folglich betrachten wir erneut die jeweils ersten Elemente und verfahren ebenso. Da wir die Operationen in-place ausführen, ist kein merge-Schritt notwendig (im Gegensatz zu MergeSort).

Beispiel 12. Wir betrachten ein Feld [8, 17, 28, 15, 11, 1, 3, 20, 25, 6, 12, 5].

Das erste Element ist folglich 8, also erhalten wir:

```
[1, 3, 6, 5, 8, 17, 28, 15, 11, 20, 25, 12].
```

Wir betrachten nun die beiden Teilmengen [1, 3, 6, 5] und [17, 28, 15, 11, 20, 25, 12].

Da 1 offensichtlich kleinstes Element der ersten Teilmenge ist, 3 anschließend ebenfalls beim nächsten Aufruf, erhalten wir schnell [1, 3, 5, 6].

In der zweiten Menge erhalten wir [15, 11, 12] und [28, 20, 25], die wir schnell zu [11, 12, 15] und [20, 25, 28], zusammen [11, 12, 15, 17, 20, 25, 28].

Abschließend erhalten wir das sortierte Feld [1, 3, 5, 6, 8, 11, 12, 15, 17, 20, 25, 28].

## Implementierung als Pseudo-Code

```
QuickSort(Array, lo, hi) {
    if (lo < hi) {
        pivot = Array[lo];
        i = lo;
        j = hi+1;
    }
    while (true) {
        while (Array[++i] < pivot && i < hi) {
        }
        while (Array[--j] > pivot && j > lo) {
        }
        if (i < j) {
            swap(Array, i, j);
        }
}</pre>
```

```
else {
                          break;
        swap(Array, j, lo);
         quickSort (Array, lo, j-1);
         quickSort(Array, j+1, hi);
}
swap(Array, i, j) {
         t = Array[i];
         Array[i] = Array[j];
         Array[i] = t;
}
abgewandelt nach [Vöc+08, S. 29]
```

Komplexität Offensichtlich handelt es sich bei Quicksort ebenfalls um einen rekursiven Sortieralgorithmus. Im günstigsten Fall ergibt sich eine Komplexität von  $O(n \cdot log(n))$ , da dann das Pivot-Element genau der Median ist und so beide Hälften glatt rekursiv abgearbeitet werden können. Im schlechtesten Fall beträgt die Komplexität  $O(n^2)$ , da dann das Pivot-Element jeweils das kleinste oder größte ist.

Wir geben die Komplexität von Quicksort im Durchschnittsfall mit  $O(n \cdot loq(n))$  an, behalten allerdings im Kopf, dass in einem ungünstigen Fall eine deutlich schlechtere Laufzeit in Kauf genommen werden muss.

#### Eigenschaften

- rekursiv
- nicht stabil
- in-place, da kein Hilfsfeld benötigt wird
- optimierbar beispielsweise durch Einfügen einer Schranke, bis zu der Insertion Sort genutzt wird (z.B. bei einer geringen zweistelligen Anzahl von Elementen) oder durch 3-Way-Partitioning, bei dem neben <, > auch der Fall = betrachtet wird. Dies ist logischerweise nur dann sinnvoll, falls es mehrere Elemente mit gleichen Schlüsseln gibt und diese bevorzugt als Pivot-Element genutzt werden.

# 14. Weitere Sortieralgorithmen

Auf weitere Sortieralgorithmen wie z.B. Selection Sort [Vöc+08], Shellsort oder Shakesort [Wir83] und [ESB16] kann hier nicht näher eingegangen werden. In genannten Büchern finden Sie nähere Informationen zu diesen Algorithmen.

# 15. Allgemeine Komplexitätsbetrachtung von Sortieralgorithmen

**Satz 5.** Ein Sortieralgorithmus, der auf Vergleichen von Datenelementen beruht, hat mindestens eine Komplexität von  $O(n \cdot log(n))$ .

Um diesen Satz zu verstehen, verdeutlichen wir uns zunächst, was eine Sortierung im Allgemeinen bedeutet:

Aus der Menge aller möglichen Permutationen (also Anordnungen) von den Elementen unserer Menge suchen wir genau die eine heraus, in der alle Elemente sortiert sind, nach unserem Kriterium. Insgesamt gibt es bei n Elementen n! Vergleiche.

**Beweisidee** Wir betrachten die Menge aller Permutationen, ordnen ihnen einen Wert zu und vergleichen nun jede Permutation mit der gewünschten, also derjenigen, in dem die Elemente vollständig sortiert sind. Nun können wir eine Hälfte an Permutationen ausmachen, deren Wert "kleiner" ist und eine weitere Hälfte, deren Wert "größer oder gleich" der Permutation ist. Hier sind nun  $\frac{n!}{2}$  Vergleiche erforderlich.

Wir halbieren die Hälften fortlaufend und erhalten im letzten Schritt die eine verbleibende Permutation.

Sie ist nach log(n!) Vergleichen erreicht.

$$O(log(n!)) \in O(n \cdot log(n))$$

Beweis.

$$n^n > n! \tag{33}$$

$$1 \cdot 2 \cdot 3 \cdot \dots \cdot (n-1) \cdot n = n \cdot (n-1) \cdot \dots \cdot 3 \cdot 2 \cdot 1 \tag{34}$$

$$(n-k)\cdot(k+1) \ge n \quad \forall 0 \le k \le n \tag{35}$$

$$(n-1)\cdot((n-1)\cdot 2)\cdot\ldots\cdot((n-k)\cdot (k+1))\cdot(1\cdot n)\geq n\cdot n\cdot\ldots\cdot n \tag{36}$$

$$n! \cdot n! \ge n^n \tag{37}$$

(1) und (4): 
$$n^{2n} \ge n! \cdot n! \ge n^n$$
 (38)

$$2n \cdot log(n) \ge 2 \cdot log(n!) \ge n \cdot log(n)$$
 (39)

$$O(\log(n!)) = O(n \cdot \log(n)) \tag{40}$$

Tatsächlich ist damit gezeigt, dass es keinen Sortieralgorithmus gibt, dessen Komplexität geringer ist als  $O(n \cdot log(n))$ .

# **Aufgaben**

Aufgabe 1 Sortieren Sie das Feld [56, 10, 15, 98, 99, 12, 30, 80] aufsteigend. Notieren Sie Zwischenschritte

- Insertion Sort
- Bubblesort
- Quicksort
- Mergesort

Lösung auf Seite 56 entnommen aus [Sch19]

Aufgabe 2 Beschreiben Sie Quicksort mit eigenen Worten.

Lösung auf Seite 56

**Aufgabe 3** Begründen Sie, mit welchen Verfahren Sie folgende Felder in optimaler Laufzeit aufsteigend sortieren können.

- [1, 9, 2, 8, 3, 7, 4, 6, 5]
- [9, 7, 7, 2, 5, 4, 7, 3, 1]
- [9, 8, 7, 6, 5, 4, 3, 2, 1]

Lösung auf Seite 56

**Aufgabe 4** Entwickeln Sie für Mergesort und Quicksort eine anschauliche Darstellungsform.

Lösung auf Seite 56

# Teil IV.

# Bäume

Vielleicht haben Sie die letzte Aufgabe vom letzten Teil gelöst – Mit relativ hoher Wahrscheinlichkeit werden Sie eine Struktur beschrieben oder skizziert haben, die wir im Folgenden näher betrachten: Bäume!

Damit Sie vor lauter Bäumen den Wald (und die Wahrheit) nicht aus den Augen verlieren, widmen wir uns in aller Ausführlichkeit diesem in der Informatik sehr häufig anzutreffenden Gebilde, denken Sie beispielsweise an Ableitungs-, Entscheidungs-, Syntax-oder Codebäume.

### 16. Der Wurzelbaum

**Definition 11.** Ein Wurzelbaum B = (V, E, r) besteht aus einer endlichen Menge von Konten V, einer endlichen Menge von gerichteten Kanten  $E \subset V \times V$  und aus der Wurzel  $r \in V$ .

- Ein Knoten r ist ein Wurzelbaum  $(B = (\{r\}, \emptyset, r)).$
- Sind  $B_1 = (V_1, E_1), ..., B_k = (V_k, E_k)$  Bäume mit den Wurzeln  $r_1, ..., r_k$ , so erweitern wir die Knotenmenge V um eine neue Wurzel r und die Kantenmenge E um die Kanten  $(r, r_i), i = 1, ...k$ .

Der Baum

$$(V_1 \cup ... \cup V_n \cup \{r\}, \{(r, r_i) \mid i = 1, ..., k\} \cup E_1 \cup ... \cup E_k, r)$$

ist ein Wurzelbaum.

Folglich betrachten wir hier nun also einen Baum mit einem Knoten, der den Ursprung darstellt, aus dem sich die anderen Knoten ableiten. In etwa so:

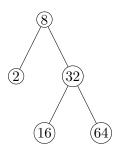


Abbildung 1: Wurzelbaum

## Beispiel 13.

Definition 12. Ein Baum, der keine Knoten und Kanten besitzt, heißt leerer Baum.

Zu diesen Bäumen, von denen es die unterschiedlichsten Formen gibt, betrachten wir nun eine Reihe von Eigenschaften und Begrifflichkeiten.

**Definition 13.** • Ist  $e = (v, w) \in E$ , so heißt v Vater von w und w Sohn oder Kind von v. Ein Knoten, der keine Söhne hat, heißt Blatt.

- Ein Pfad P in B ist eine Folge von Knoten  $v_0, ..., v_n$  mit  $(v_i, v_{i+1}) \in E, i = 0, ..., n 1.n$  heißt Länge von P.
- Seien  $v, w \in V$ . Der Knoten w heißt **von Knoten** v **aus erreichbar**, falls es einen Pfad P von v nach w gibt.
- Jeden Knoten v von B können wir als Wurzel des Teilbaums der von v aus erreichbaren Knoten betrachten.

Hat v die Söhne  $v_i, ..., v_k$ , so heißen die Bäume  $B_1, ..., B_k$  mit den Wurzeln  $v_i, ..., v_k$  die **Teilbäume** von V.

- Die **Höhe** eines Knotens v ist das Maximum der Längen aller Pfade, die in v beginnen.
- Die **Tiefe** eines Knotens ist die Länge des Pfades von der Wurzel zu v.

Die Knoten der Tiefe i bilden die i-te Ebene des Baumes.

- Die Höhe (und auch Tiefe) eines Baumes (nicht Knotens!) ist gegeben durch die Höhe der Wurzel.
- Ein leerer Baum besitzt die Höhe/Tiefe −1.
- Die Ordnung eines Baumes ist die maximale Anzahl an Söhnen eines Knotens.

Zur Veranschaulichung wenden wir diese Begriffe auf den folgenden Beispielbaum an:



Abbildung 2: Beispielbaum

Beispiel 14. • 50 ist die Wurzel des Baumes.

• 6.25 ist Sohn/Kind von 12.5 und Blatt, da es keine Söhne hat.

- 12.5 ist erreichbar von 50, da es einen Pfad gibt. Generell ist jedes Element eines Wurzelbaums von der Wurzel aus erreichbar.
- 87.5 ist von 6.25 aus nicht erreichbar, da es keinen Pfad gibt.
- Die Höhe von 75 beträgt 1. Die Tiefe von 6.25 beträgt 3.
- Die Höhe/Tiefe des Baumes beträgt 3.
- Die Ordnung des Baumes ist 2, da kein Knoten mehr als zwei Kinder hat.

## 17. Binäre Bäume

Definition 14. Ein Baum mit der Ordnung 2 heißt binärer Baum. Liegen die Elemente darin in geordneter Form vor, d.h. der Wert des linken Sohnes ist stets kleiner und der Wert des rechten Sohnes ist stets größer als sein Vater, spricht man von einem geordneten binären Baum [Wir83] oder binären Suchbaum.

Diese besonderen Bäume wollen wir nun näher betrachten, da wir in binären Bäumen algorithmisch vorgehen können und so beispielsweise Suchprobleme lösen.

**Bemerkung 4.** Sei n die Anzahl der Knoten in einem binären Baum der Höhe h. Dann ist die Anzahl der Knoten  $n \leq 2^{n+1} - 1$  oder äquivalent dazu. Die Höhe h ist mindestens  $log_2(n+1) - 1$ , also  $\lceil log_2(n+1) \rceil - 1 \leq h$ . Diese Schranke wird für einen binären Baum, in dem alle Ebenen vollständig besetzt sind, angenommen.

Implementierung Wie schon eingangs erwähnt, hängen Bäume und Rekursion naturgemäß eng beieinander. Dies zeigt sich, wenn wir eine Implementierung eines binären Baums betrachten:

```
struct node {
    int key;
    type value;
    node left, right;
}
```

Ein Knoten besteht also wiederum selbst aus Knoten, im Falle eines Blattes sind left und right dann leer. Wichtig ist die Unterscheidung zwischen key und value – hier kann es leicht zu Unklarheiten kommen.

#### 17.1. Traversierung von Binärbäumen

Auf Baumstrukturen lassen sich verschiedene Operationen durchführen. Grundlage dafür ist häufig ein traversieren ("durchlaufen") des Baumes. Dafür gibt es drei, jeweils rekursiv implementierte Vorgehensweisen, die unter anderem bei [Wir83] beschrieben werden:

- Preorder W, A, B (besuche Wurzel vor den Teilbäumen)
- Inorder A, W, B
- Postorder A, B, W (besuche Wurzel nach den Teilbäumen)

Grundlage dafür ist der allgemeine binäre Baum:



Abbildung 3: Allgemeiner binärer Baum

Beispiel 15. Betrachten wir den Baum aus vorangegangenem Beispiel und traversieren wir diesen in allen drei Varianten:

#### Preorder

50, 25, 12.5, 6.25, 37.5, 75, 63.5, 87.5

#### In order

6.25, 12.5, 25, 37.5, 50, 63.5, 75, 87.5

#### Postorder

6.25, 37.5, 12.5, 25, 63.5, 87.5, 75, 50

Neben den drei genannten Vorgehenweisen betrachten wir noch die klassische, den Baum in seinen Ebenen ausgebende: levelorder. Auf unser Beispiel bezogen wäre dies: 50, 25, 75, 12.5, 37.5, 63.5, 87.5, 6.25

#### 17.2. Operationen

Auf binären Bäumen lassen sich nun drei Operationen konstruieren: Suchen, Einfügen und Löschen.

**Suchen** Ein Baum wird durchsucht, in dem jeweils das Suchelement mit dem Wert des Knotens verglichen und anschließend mit dem linken Sohn, falls das gesuchte Element kleiner ist, oder dem rechten Sohn, falls das gesuchte Element größer ist, als neuen Knoten rekursiv fortgefahren.

**Einfügen** Ähnlich läuft das Einfügen eines Elements k mit Wert v:

```
node Insert(int k, node Tree, type v) {
    if (T == null) {
        return "neuer Knoten (k, v)";
    }
    else if (k < T.key) {
            T.left = Insert(k, T.left, v);
    }
    else if (k > T.key) {
            T.right = Insert(k, T.right, v);
    }
    else if (k == T.key) {
            T.value = v;
    }
    return T;
}
```

Ein Einfügen kann folglich auch ein "Wert ändern" sein.

**Löschen** Das Löschen eines Knotens gestaltet sich etwas aufwendiger. Suche Zeiger T auf den zu löschenden Schlüssel/Knoten und unterscheide:

- Das zu löschende Element hat keine Kinder: Setze Zeiger T auf null
- Das zu löschende Element hat ein Kind: Ersetze T durch den Zeiger auf den Kindknoten
- Das zu löschende Element hat zwei Kinder: Ersetze den gelöschten Knoten durch den kleinsten Schlüssel des rechten Teilbaums.

Eine Implementierung davon finden Sie bei [Wir83].

**Komplexität** Für die Suche und das Löschen liegt die Komplexität im Durchschnittsfall in O(n), wobei n die Höhe des Baumes ist. Unter günstigen Umständen ist auch eine Komplexität von  $O(\log(n))$  möglich. Die Komplexität des Einfügens liegt in O(1).

#### 18. AVL-Bäume

Ein weiterer Typ von Bäumen sind die sogenannten **AVL-Bäume**, die durch einen geringen zusätzlichen Aufwand beim Einfügen/Löschen erzeugt werden und eine günstigere Komplexität besitzen.

**Definition 15.** Ein binärer Baum heißt **(AVL-)ausgeglichen**, falls für jeden Konten v gilt:

Die Höhen des linken und rechten Teilbaums unterscheiden sich höchstens um 1. Diese Differenz der Höhen heißt **Balance** von v.

$$Balance = h(rT) - h(lT)$$

Ausgeglichene, binäre Suchbäume heißen nun AVL-Bäume.

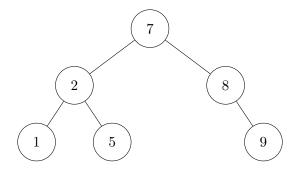


Abbildung 4: Beispiel für einen AVL-Baum

Beispiel 16. Dieser Baum ist ein AVL-Baum, da er die drei Kriterien erfüllt:

- binär: Alle Knoten haben höchstens zwei Kinder, mindestens ein Knoten hat mindestens zwei Kinder
- Suchbaum: Alle Elemente im linken Teilbaum sind kleiner als das Wurzelelement des Teilbaums, alle Elemente im rechten Teilbaum sind größer als der Teilbaum
- AVL-Kriterium: Die Balancen der Teilbäume unterscheiden sich höchstens um 1.

Kein AVL-Baum hingegen ist der folgende: Hier ist die AVL-Bedingung offensichtlich

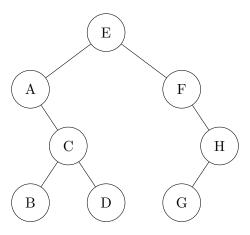


Abbildung 5: Kein Beispiel für einen AVL-Baum

verletzt: Die Balance an den Knoten A und F ist jeweils größer als 1. Damit handelt es sich nicht um einen AVL-Baum.

Um zu ermitteln, ob es sich bei einem Baum um einen AVL-Baum handelt, prüfen wir also zunächst, ob es sich um einen binären Suchbaum handelt. Nun bestimmen wir zu jedem Knoten die Balance: Jedes Blatt hat die Balance 0, falls der rechte Teilbaum eine größere Höhe hat, ist die Balance positiv. Falls der linke Teilbaum eine größere Höhe hat, ist die Balance negativ. Eine Balance von 1 / -1 wird toleriert, alle größeren Balancen führen dazu, dass der Baum kein AVL-Baum sein kann. Ein Knoten mit Balance größer 1 genügt.

Bemerkung 5. Für die Höhe eines ausgeglichenen Baumes mit n Knoten gilt:

$$h < 1.45 \cdot log_2(n+2) - 1.33$$

Dieses Kriterium eignet sich aus naheliegenden Gründen lediglich für eine Abschätzung.

**Suche** Da ein AVL-Baum ein binärer Suchbaum ist, verwenden wir zum Suchen die Suchfunktion eines binären Suchbaums. Das AVL-Kriterium hat keine Auswirkungen auf die Komplexität.

**Einfügen** Wir suchen nach dem einzufügenden Element e. Falls e nicht im Baum, endet die Suche in einem Blatt. An diesem Blatt verankern wir einen neuen Knoten und füllen ihn mit e. **Hierbei kann die AVL-Bedingung verletzt werden!** 

Anschließend reorganisieren wir den Baum, um die AVL-Bedingung wiederherzustellen:

- $\bullet$  Prüfe für jeden Knoten n des Suchpfades, ob er ausgeglichen ist.
- Falls nicht: Rotation

**Rotation** Rotation können wir uns vorstellen als eine Art "Kippen" eines Knotens, um eine Balance wiederherzustellen bzw. zu nivellieren. Wir unterscheiden zwei Rotationsarten:

- Linksrotation (LR) Ein rechtes Kind kann nach links rotiert werden.
- Rechtsrotation (RR) Ein linkes Kind kann nach rechts rotiert werden.

Rotation ist möglich, da ein vormals linkes Kind – das kleiner als die Wurzel ist – auch die neue Wurzel mit der vorherigen Wurzel als neues rechtes Kind – das dann weiterhin größer ist – sein kann. Im Prinzip ändert sich folglich jeweils nur die Verwandtschaftsbeziehung zwischen Kind und Wurzel mit dem Effekt, dass auch die Kinder neu, meistens paritätischer, angeordnet werden.

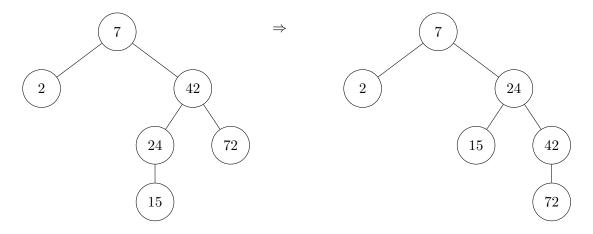


Abbildung 6: AVL-Baum mit Rechtsrotation des Knotens 24

Beispiel 17. Der hier vorliegende Baum wurde am Knoten 24 nach rechts rotiert. Dadurch ist die 24 die neue Wurzel geworden, während die 42 nun eine Ebene tiefer ein Kind geworden ist. Doch auch nach dieser Rotation zeigt sich, dass die AVL-Bedingung weiterhin nicht erfüllt ist. Also ist ein weiterer Rotationsschritt notwendig: Nun zeigt sich, dass die AVL-Bedingung wieder erfüllt ist.

Aus dem Beispiel können wir nun die Fälle für Rotationen unterscheiden:

• Eine einfache Rotation wird dann notwendig, wenn

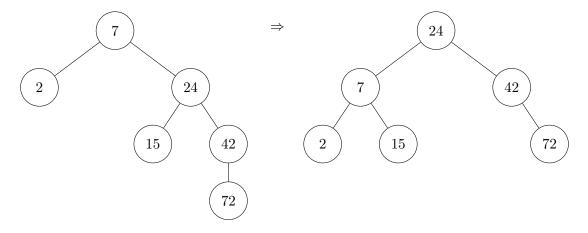


Abbildung 7: AVL-Baum mit Linksrotation des Knotens 24

- in einem linken Teilbaum ein linkes Kind eingefügt wird  $\rightarrow$  einfache Rechtsrotation
- -in einem rechten Teilbaum ein rechtes Kind eingefügt wird  $\rightarrow$  einfache Linksrotation
- Eine zweifache Rotation wird hingegen angewandt, falls
  - -in einem linken Teilbaum ein rechtes Kind eingefügt wird  $\to$  Links-Rechts-Rotation
  - -in einem rechten Teilbaum ein linkes Kind eingefügt wird  $\rightarrow$  Rechts-Links-Rotation

**Löschen** Zunächst wird wie in einem binären Suchbaum vorgegangen. Anschließend muss – wie beim Einfügen – die AVL-Bedingung durch Rotationen wiederhergestellt werden.


Für die Betrachtung der Komplexität ergibt sich nun:

**Theorem 1.** Die Operationen Suchen, Einfügen und Löschen eines Schlüssels können in O(log(n)) durchgeführt werden.

## **Aufgaben**

Aufgabe 1 Gegeben ist der folgende Baum.

- ullet Geben Sie folgende Eigenschaften an: Wurzel, Höhe des Baumes, Höhe des Knotens E, Ordnung des Baumes, Balance des Knotens K
- $\bullet\,$  Fügen Sie den Knoten J hinzu.
- $\bullet$  Löschen Sie den Knoten B.



Lösung auf Seite 56

**Aufgabe 2** Untersuchen und begründen Sie, ob es sich bei diesem Baum um einen AVL-Baum handelt. Fügen Sie hierzu die Balancen jedes Knotens ein.

Lösung auf Seite 56

**Aufgabe 3** Falls es sich nicht um einen AVL-Baum handelt, ergänzen Sie den Baum zu einem AVL-Baum und führen Sie dann folgende Aufgabe aus.

- $\bullet$  Löschen Sie den Knoten A.
- $\bullet\,$  Fügen Sie den Knoten Zhinzu.

Falls Rotationen erforderlich sind, stellen Sie diese detailliert dar.

Lösung auf Seite 56

**Aufgabe 4** Beschreiben Sie in Worten und Pseudocode das Vorgehen beim Suchen eines Elementes in einem binären Baum. Beurteilen Sie, ob dieses Verfahren auch in einem Baum der Ordnung 3 angewendet werden kann.

Lösung auf Seite 56

## Teil V.

## **Heaps**

Eigentlich auch zu Bäumen gehörend, betrachten wir im Folgenden die Datenstruktur **Heap**. Als Heap bezeichnen wir eine Struktur (einen "Haufen") von Objekten, die über Schlüssel mit einer Priorität versehen sind. Wirth definiert Heaps in [Wir83, S. 92] wie folgt:

**Definition 16.** Ein heap ist definiert als eine Folge von Schlüsseln h[l], h[l+1], ..., h[r] mit den Relationen:

- $h[i] \leq h[2i]$
- $h/i \le h/2i+1/ \forall i = 1...r/2$

Betrachten wir einen Heap als Baum, so ist h[2i] das linke Kind des Knotens h[i] und h[2i+1] entsprechend das rechte. Somit muss jede Wurzel eines Teilbaums kleiner als ihre Kinder sein. Diese Struktur bezeichnen wir als **Min-Heap**. Invers dazu bezeichnen wir Heaps, in denen die Wurzel eines Teilbaums jeweils größer ist als ihre Kinder als **Max-Heap**. Beide Varianten finden sich in der Literatur. Da in der Vorlesung lediglich der Max-Heap eingeführt wurde, beschränken wir uns der Übersichtlichkeit halber auf diesen Typ.

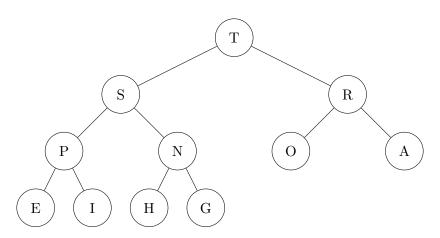


Abbildung 8: Binärer Max-Heap

#### Beispiel 18.

Wir erkennen und formulieren als Eigenschaften:

- Es handelt sich um einen (fast) vollständigen Binärbaum, d.h. die Blätter befinden sich auf höchstens zwei verschiedenen Levels.
- Die Blätter auf dem untersten Level sind linksbündig angeordnet.

Implementierung eines Heaps als Array Ein Heap lässt sich als Feld/Array implementieren, da für die Indizes die oberen Bedingungen leicht erkannt und umgesetzt werden können. Als Array erhalten wir damit: In A[0] speichern wir die Größe des Heaps, in diesem Fall 11, da es sich um 11 Elemente handelt.

Wir können erneut festhalten:

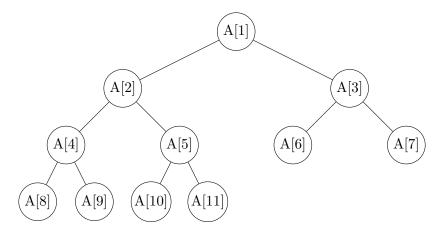


Abbildung 9: Binärer Max-Heap in Array-Darstellung

0	1	2	3	4	5	6	7	8	9	10	11	
11	T	S	R	P	N	O	A	E	T	H	G	

- A[i] hat linkes Kind A[2i]
- A[i] hat rechtes Kind A[2i+1]
- A[i] hat Vater  $A[\frac{i}{2}]$  (bei Ganzzahldivision)
- A[i] befindet sich auf dem Level  $\lfloor log_2(i) \rfloor$

## 19. Herstellen der Heap-Eigenschaft

Um sicherzustellen, dass es sich bei einem gegebenen Baum um einen Heap handelt, unterscheiden wir zwei Szenarien.

• Szenario 1: Der Schlüssel eines Kindes ist größer als der Schlüssel eines Elternknotens. Dann vertauschen wir – logischerweise – den Schlüssel des Kindes mit dem Schlüssel des Elternknotens. Das Kind "schwimmt nach oben", deshalb heißt dieses Vorgehen auch swim-up.

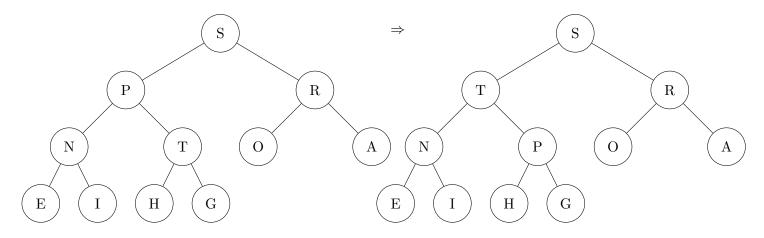


Abbildung 10: Herstellen der Heap-Eigenschaft durch swim\_up(T) im ersten Schritt

Beispiel 19. Dieser Baum ist noch kein Heap, da der Knoten T weiterhin größer ist als S. Folglich wiederholen wir das Vorgehen, für alle Knoten, bis die alle Beziehungen zwischen Kindern und Eltern passen.

Wir implementieren die Methode swim\_up wie folgt:

• Szenario 2: Der Schlüssel eines Elternknotens ist kleiner als der Schlüssel eines/beider Kinder: Dann vertauschen wir den Schlüssel des Elternknotens mit dem Schlüssel des größeren Kindes.

## 20. Einfügen eines Elementes

Das Einfügen eines Elementes in einen Heap erfolgt zunächst an der nächsten freien Position im Array. Also falls wir einen bestehenden Heap der Länge 11 betrachten, fügen wir das Element an der Position 12 ein. Anschließend wird die Heap-Eigenschaft durch swim\_up wiederhergestellt.

Die Komplexität des Einfügens liegt in O(log(n)).

Implementierung:

```
\label{eq:condition} \begin{array}{lll} void & insert (A[]\;,\;\; key\_type \;\; Element) \;\; \{ \\ & \;\; heap\_size \, (A)++; \\ & \;\; A[\; heap\_size \, (A)\,] \;\; = \;\; Element\;; \\ & \;\; swim\_up \, (A,\;\; heap\_size \, )\;; \\ \} \end{array}
```

### 21. Löschen des größten Elements

In einem Heap ist das Löschen zunächst nur für das größte Element (also im Max-Heap die Wurzel) definiert. Wir tauschen die Wurzel mit dem letzten Element im Heap, erhalten dadurch eine neue Wurzel. Das neue letzte Element kann nun einfach entfernt werden, indem wir die Größe des Arrays um 1 verringern. Nun ist abschließend noch die Heap-Eigenschaft durch Absinken lassen der neuen Wurzel herzustellen.

Auch diese Operation verläuft in O(log(n)).

Implementierung:

```
key_type del_max(A[]) {
    key_type max = A[1];
    exchange(A[1], A[heap_size(A)]);
    heap_size(A)--;
    sink(A, 1, heap_size(A));
    return max;
}
```

### 22. Heapsort

Nun lässt sich auf Heaps auch ein Suchalgorithmus definieren, den wir im Folgenden betrachten und anwenden wollen. Auch wenn wir Heaps zunächst als Baumstruktur eingeführt haben, wird von Ihnen in Klausuren verlangt werden, die Konzepte und Methoden – also auch Heapsort – auf bloße Arrays anzuwenden. Versuchen Sie daher, sich die Beziehung zwischen Heaps als Bäumen und Heaps als Array zu verinnerlichen.

**Idee** Ausgehend von einem ungeordneten Feld, stellen wir zunächst die Heap-Eigenschaft her. Nun steht – zumindest bei Max-Heaps – der größte Schlüssel in der Wurzel bzw. an Index 1. Nun tauschen wir den Schlüssel der Wurzel mit dem Schlüssel an der letzten Stelle des Feldes. Nun stellen wir die Heap-Eigenschaft über sink wieder her und tauschen die neu gewonnene Wurzel mit dem letzten Feldelement, solange noch Schlüssel ungeordnet sind. Die Anzahl der noch ungeordneten Schlüssel erhalten wir dadurch, dass wir das Feld nach jeder Iteration verkürzen.

#### Implementation als Pseudo-Code

Beispiel 20. Betrachten wir das ungeordnete Array [ 6 9 1 8 2 3 5 4 ]. Zunächst stellen wir die Heap-Eigenschaft her, in dem wir sink() aufrufen.

Nun beginnen die Vertauschungsoperationen:

```
2
                  3
                         9
       5
           6
              2
                  3
                     1
                         9
       5
          4
              2
                  3
                     1
                         9
              2
                  3
                     8
                         9
1
   6
       5
          4
6
   1
       5
          4
              2
                  3
                     8
                         9
              2
                  3
                     8
                         9
           1
              2
                  6
                     8
3
   4
       5
           1
                         9
   4
       3
              2
                  6
                     8
                         9
5
           1
2
       3
                  6
   4
           1
              5
                     8
                         9
   2
4
       3
           1
              5
                  6
                     8
                         9
1
   2
       3
           4
              5
                  6
                     8
                         9
   2
3
       1
              5
                     8
                         9
          4
                  6
   2
1
       3
          4
              5
                         9
                  6
2
   1
       3
           4
              5
                  6
                     8
                         9
1 \mid 2
                         9
      3
          4
             5
                  6
                    8
```

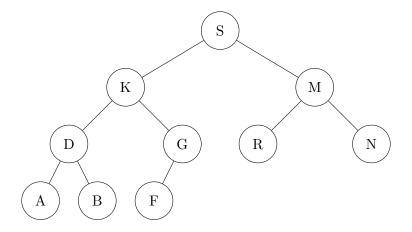
Im letzten Schritt haben wir das gewünschte, aufsteigend sortierte Array erhalten.

**Komplexität** Wie alle anderen Sortieralgorithmen ist auch Heapsort nicht laufzeiteffizienter als  $O(n \cdot log(n))$ . Für das Herstellen der Heap-Eigenschaft erhalten wir eine Komplexität von O(n), da wir im schlechtesten Fall alle Elemente des Arrays einmal vertauschen müssen. Für die eigentliche Suche erhalten wir  $O(n \cdot log(n))$ .

## **Aufgaben**

Aufgabe 1 Gegeben ist der folgende Baum.

- Beurteilen und begründen Sie, ob es sich bei diesem Baum um einen Heap handelt.
- Falls es sich nicht um einen Heap handelt, stellen Sie die Heap-Eigenschaft her.
- $\bullet$  Fügen Sie das Element X hinzu.



Lösung auf Seite 56

Aufgabe 2 Sortieren Sie den Baum aus Aufgabe 1 mittels heapsort() absteigend.

Lösung auf Seite 56

Aufgabe 3 Sortieren Sie die folgenden Arrays mittels heapsort() aufsteigend.

- [7 1 3 9 4 6 5 8]
- $\bullet$   $\begin{bmatrix} H & S & G & A & V & D & J & K \end{bmatrix}$

Lösung auf Seite 56

Aufgabe 4 Erläutern Sie, inwiefern anstatt der Funktion sink() die Funktion swim\_up() in heapsort() verwendet werden könnte. Geben Sie an, wie sich der Algorithmus ändert und stellen Sie dies in Pseudocode dar.

Lösung auf Seite 56

## Teil VI.

# Graphentheorie

Nach unserem Ausflug in besondere Bäume (den Heaps) begeben wir uns nun wieder auf eine abstraktere Ebene, diesmal sogar über Bäume hinaus: Im Folgenden betrachten wir Graphen allgemein und gehen auf Themen wie Pfade, Richtungen oder die Suche nach dem kürzesten Weg ein. Sie haben sicherlich eine Intuition, wenn Sie sich durch eine Stadt bewegen, welcher denn nun der kürzeste Weg ist – während ein Computer damit beschäftigt wäre, Optionen durchzuprobieren. Insofern erscheint es sinnvoll, dafür praktikable Algorithmen zu finden und zu behandeln. Doch beginnen wir von vorne.

### 23. Typisierung und Eigenschaften

**Definition 17.** Ein gerichteter Graph ist ein Paar G = (V, E), wobei V eine nichtleere Menge und  $E \subseteq V \times V$  ist. V heißt die **Menge der Knoten** und E heißt die **Menge der (gerichteten) Kanten**. Ein Knoten v heißt **benachbart** oder **adjazent** zu v, wenn  $(v, w) \in E$ . v heißt Anfangspunkt und w heißt Endpunkt der Kante (v, w). Eine Kante (v, v), die also von einem Knoten auf diesen selbst gerichtet ist, bezeichnen wir als **Schleife**.

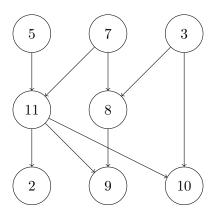


Abbildung 11: Gerichteter Graph

#### Beispiel 21.

**Definition 18.** Bei einem ungerichteten Graphen besitzen die Kanten keine Richtung. v und w heißen Endpunkte der Kante  $e = \{v, w\}$ . Die Kante  $\{v, w\}$  heißt inzident zu v und zu w.

Zu beiden Typen von Graphen können wir nun Eigenschaften und Kennzahlen definieren:

**Definition 19.** Sei  $v \in V$ .

$$U(v) := \{ w \in V \mid w \text{ adjazent zu } v \}$$

heißt Umgebung von v. Die Anzahl |U(v)| der Elemente von U(v) heißt Grad von v,  $kurz\ deg(v)$ .

Die Anzahl der Knoten |V| heißt Ordnung von v.

Damit ergibt sich:

- |V| und |E| messen die Größe eines Graphen. Daher geschehen Aufwandsschätzungen über Graphen stets in Abhängigkeit zu diesen beiden Angaben.
- Einem gerichteten Graphen kann man einem ungerichteten Graphen zuordnen: Kante  $(v, w) \to \text{Kante}\{v, w\}$ .
- Dem einem Graphen zugeordneten gerichteten Graphen erhalten wir, wenn wir jede Kante  $\{v, w\}$  durch die Kanten (v, w) und(w, v) ersetzen.

**Definition 20.** Sei G = (V, E) ein ungerichteter Graph.

- Ein **Pfad** P ist eine Folge von Knoten  $v_0, v_1, ..., v_n$  mit der Eigenschaft  $\{v_i, v_{i+1}\} \in E, i = 0, ..., n-1$ . Dann heißt  $v_0$  **Anfangspunkt** und  $v_n$  **Endpunkt** von P. n heißt **Länge** von P.
- w heißt von v erreichbar, falls es einen Pfad P mit Ausgangspunkt v und Endpunkt w gibt.

Für gerichtete Graphen definieren wir die Begriffe analog, in einem Pfad sind die Kanten dann gerichtet enhalten.

**Satz 6.** Sei G = (V, E) ein Graph ohne Schleifen. Dann sei n := |V| und m := |E|.

- Für einen Graphen gilt:  $0 \le m \le \binom{n}{2}$
- Für einen gerichteten Graphen gilt:  $0 \le m \le n \cdot (n-1)$ .

Falls Graphen mit Schleifen betrachtet werden, gilt alternativ:

- Für einen Graphen gilt:  $0 \le m \le \binom{n}{2} + n$
- Für einen gerichteten Graphen gilt:  $0 \le m \le n^2$ .

Nun haben wir schon eine Vielzahl von Begrifflichkeiten zu Graphen definiert. Sie finden, das reicht? Nun ...

**Definition 21.** Für einen Graphen eines beliebigen Typs definieren wir:

- G = (V, E) heißt **vollständig**, wenn jeder Knoten mit jedem anderen Knoten durch eine Kante verbunden ist.
- Besitzt G viele Kanten (m groß im Vergleich zu  $\binom{n}{2}$  oder  $n \cdot (n-1)$ ), dann heißt G dicht besetzt.
- Besitzt G wenige Kanten, dann heißt G analog dazu dünn besetzt.

Daraus folgt:

Für einen vollständigen Graphen gilt  $|E| = n \cdot (n-1)$  im Fall eines gerichteten Graphen und  $|E| = n^2$  für einen ungerichteten Graphen.

### 24. Adjazenzmatrizen und -listen

"Ein guter Nachbar ist besser als viele böse Verwandten."
— Ungarisches Sprichwort

Falls Sie erinnern, wie wir Adjazenz definiert haben, werden Sie eine Intuition dafür haben, womit wir uns hier beschäftigen wollen: Wir betrachten Nachbarschaftsverhältnisse in Graphen. Dafür nutzen wir zwei Darstellungsformen, die Adjazenzmatrix und die Adjazenzliste. Hierbei handelt es sich tatsächlich nur um verschiedene Darstellungsformen, der Inhalt unterscheidet sich nicht.

**Definition 22.** Die Adjazenzmatrix ist eine  $n \times n$ -Matrix mit Koeffizienten aus  $\{0,1\}$ .

$$adm[i,j] := \begin{cases} 1 & \textit{für } (i,j) \in E \\ 0 & \textit{sonst} \end{cases}$$

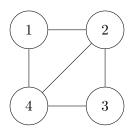


Abbildung 12: Ungerichteter Graph zur Veranschaulichung der Adjazenzmatrix

Beispiel 22. Wir entnehmen der Darstellung, dass die Knoten (1, 2), (2, 3), (3, 4), (1, 4) und (2, 4) benachbart sind. Also muss an diesen Indizes der Matrix eine 1 stehen, in allen übrigen Fällen entsprechend eine 0.

$$\left(\begin{array}{cccc}
0 & 1 & 0 & 1 \\
1 & 0 & 1 & 1 \\
0 & 1 & 0 & 1 \\
1 & 1 & 1 & 0
\end{array}\right)$$

Betrachten wir nun vergleichsweise diesen Graphen in einer gerichteten Variation: Hier ergibt sich eine andere Matrix, da die Nachbarschaftsverhältnisse einseitig sind und

wir also für jeden Knoten betrachten, auf welche Knoten er (durch einen so gerichteten Pfeil) "zugreifen" kann.

$$\left(\begin{array}{cccc}
0 & 1 & 0 & 1 \\
0 & 0 & 1 & 1 \\
0 & 0 & 0 & 1 \\
0 & 0 & 0 & 0
\end{array}\right)$$

51

Nun definieren wir alternativ dazu:

**Definition 23.** Die **Adjazenzliste** adl[1,...,n] ist ein Array von Listen. Für jeden Knoten  $j \in V$  ist die Liste adl[j] definiert durch  $i \in adl[j]$  genau dann, wenn  $(j,i) \in E$  gilt.

Also sind in adl[j] ebenfalls die zu j adjazenten Knoten verzeichnet.

Beispiel 23. Für obiges Beispiel ergibt sich nun im Fall des ungerichteten Graphen:

```
1: 2, 4
2: 1, 3, 4
3: 2, 4
4: 1, 2, 3
Und im Fall des gerichteten Graphen:
1: 2, 4
2: 3, 4
3: 4
4:
```

**Eigenschaften** Die Adjazenzmatrix ist speichereffizient für dicht besetzte Graphen (immer  $O(n^2)$ ). Die Suche nach einer bestimmten Kante verläuft in O(1), ist also logischerweise sehr effizient.

Eine Adjazenzliste hat m Einträge bei gerichteten und  $2 \cdot m$  Einträge bei ungerichteten Graphen. Für dünn besetzte Graphen ist sie besser geeignet.

# Teil VII. Lösungen

### 25. Grundlagen der Algorithmik

**Lösung zu Aufgabe 1** Gesucht sind die Landau-Notationen  $O, \Omega, \Theta$  zur Funktion  $3n^3 + 7n^2 + 16$ . Zunächst bestimmen wir die O-Komplexitätsklasse: Da der höchste Grad des Polynoms 3 ist und sämtliche konstanten Faktoren oder Summanden entfallen, liegt die Funktion in  $O(n^3)$ .

Für die  $\Omega$ -Notation überlegen wir uns Folgendes: Der kleinste Grad des Polynoms ist 0  $(16 \cdot n^0)$ . Dies ist unsere Unterschranke: Da auch hier konstante Faktoren und Summanden unberücksichtigt bleiben, erhalten wir  $\Omega(1)$ .

Die  $\Theta$ -Notation umfasst nun alle Funktionen, die sowohl Teil von  $O(n^3)$  als auch von  $\Omega(1)$  sind. Dies ist nun keine zeichenbare Funktion, sondern viel mehr der Flächeninhalt zwischen beiden Graphen.

Wir zeichnen nun ein:




Abbildung 13: Skizze zu Aufgabe 1.1

Lösung zu Aufgabe 2 Anzugeben sind die O-Notationen zu gegebenen Funktionen.

- 1.  $f(n) = 6n^4 + 3 \cdot log_2(n) \in O(n^4)$ , da das Wachstum des Terms  $n^4$  im Vergleich zu  $log_2(n)$  m größten ist. Konstantglieder entfallen.
- 2.  $f(n) = 6627816n + 13 \in O(n)$ , da Konstantglieder immer entfallen und somit n das größte Wachstum verursacht.
- 3.  $f(n) = \frac{72n^3 + 27n^2 + 8n + 9}{n!} \in \frac{O(n^3)}{O(n!)}$ . Diese Angabe genügt, ein weiteres Auflösen ist nicht möglich oder sinnvoll. Diese Funktion kann keine typische Komplexität eines Algo-

rithmus sein, da die Funktion gegen 0 konvergiert. Falls Sie sich an dieser Aufgabe die Zähne ausgebissen haben sollten, bitte ich um Vergebung!

4.  $f(n) = 3n \cdot \frac{n!}{2} + n^n \in O(n^n)$ , da dieser letzte Summand  $n^n$  das größte Wachstum aufweist. Es ist damit Teil der letzten Klasse des exponentiellen Wachstums und selbst innerhalb dieser durch a = n besonders schnell wachsend.

**Lösung zu Aufgabe 3** Aus gegebener Tabelle der Komplexitätsklassen wissen wir bereits, dass exponentielles Wachstum im Vergleich am schnellsten wächst. Hier ist nun zu zeigen, dass dies für sowohl für  $n^2$  als auch für  $n^3$  gilt, also beide Funktionen Teil der Komplexitätsklasse  $O(2^n)$  sind (also nicht schneller wachsen als  $2^n$ ).

Dies beweisen wir induktiv:

Beweis. Aus der Definition der O-Notation leiten wir ab, dass wir ein beliebiges  $n_0$  und ein c wählen können. Wir setzen  $n_0 = 4$ , da wir wissen, dass  $4^2 \le 2^4$  ist. 4 ist die erste natürliche Zahl, ab der dies gilt. Dass kleinere n dies noch nicht erfüllen, ist unerheblich. c = 1, da hier kein Konstantfaktor benötigt wird.

Induktions  
anfang 
$$4^2 \le 2^4$$
  
Induktionsvoraussetzung  $n^2 \le 2^n$   
Induktionsschritt  $n \to n+1$   
Ausmult. + Einsetzen der IV  $(n+1)^2 = n^2 + 2n + 1 \le 2^n + 2n + 1$ 

• • • •

Der Rest des Beweises ist in den Vorlesungsunterlagen ersichtlich. Für den zweiten Aufgabenteil gehen wir ähnlich vor.  $\Box$ 

Lösung zu Aufgabe 4 Hier wenden wir das Master-Theorem an.

•  $f(n) = 2 \cdot f(\frac{n}{2n+1}) + n^2$ , daraus folgt: a = 2, b = 2n+1, d = 2. Nun prüfen wir, ob gilt:

$$a < b^d \to 2 < (2n+1)^2 \to 2 < 4n^2 + 2n + 1$$

Offensichtlich gilt die Aussage und somit tritt Fall 1 des Mastertheorems ein und wir erhalten:  $O(n^2)$ .

•  $g(n) = log(n) \cdot g(\frac{n}{2}) + 3$ , also: a = log(n), b = 2, d = 1. Wir prüfen, ob die Bedingung des ersten Falls des Master-Theorems gilt:

$$a < b^d \to log(n) < 2^1 \to log(n) < 2$$

Offensichtlich gilt diese Bedingung nicht, da log(n) für alle  $n \ge 100$  größer ist als 2. Also tritt Fall 3 des Mastertheorems ein und wir erhalten:  $O(n^{log_2(log(n))})$ .

•  $h(n) = sin(n) \cdot h(\frac{n}{\frac{n}{2}}) + O(n^3)$ , also  $a = sin(n), b = \frac{n}{2}, d = 3$ . Wir prüfen erneut:

$$a < b^d \rightarrow sin(n) < (\frac{n}{2})^3$$

Da sin(n) nur Werte zwischen -1 und 1 annimmt, ist die Bedingung für hinreichend große n erfüllt. Damit erhalten wir:  $O(n^3)$ .

Auch bei der Anwendung des Mastertheorems ist für uns die langfristige Entwicklung des Wachstums relevant. Daher sind kleine n, die einen Widerspruch darstellen würden, unerheblich.

54

Lösung zu Aufgabe 5 Wir betrachten die Anweisungen zunächst einzeln:

int[] result; O(1)Speicher wird reserviert for (dataElement in data) O(n)In Abhängigkeit zu n if (...) O(1) konstanter Vergleich result.append(dataElement O(1)pro Iteration konstant, wegen Obergrenzenbetrachtung fällt Bedingung nicht ins Gewicht return result; O(1)konstante Ausgabe

Wir addieren nun alle Komplexitäten und erhalten  $O(n+4) \in O(n)$  als Gesamtkomplexität dieses Algorithmus.

Lösung zu Aufgabe 6 Hier finden wir drei ineinander verschachtelte For-Schleifen:

- 1. Der Iterator der ersten For-Schleife wird in jedem Durchlauf verdoppelt und beginnt bei i=0 bricht ab, sobald  $i \geq n$ . Wir suchen nun also ein x mit  $2^x=n$ . Die Gleichung lösen wir durch den Logarithmus und erhalten entsprechend  $O(\log_2(n))$ .
- 2. In der zweiten Schleife halbieren wir j in jedem Durchlauf. j initialisieren wir mit n und lassen die For-Schleife laufen, bis  $j \leq 0$ . Also gehen wir im Prinzip wie in der ersten Schleife vor, bloß in umgekehrter Richtung. Dennoch erhalten wir auch hier eine Komplexität von  $O(log_2(n))$ .
- 3. In der dritten For-Schleife lassen wir k von 1 bis n laufen und inkrementieren k in jeder Iteration um 1. Also finden hier insgesamt n-1 Durchläufe statt, was uns verdächtig stark an O(n) erinnert, womit wir auch goldrichtig liegen.

Nun multiplizieren wir die Komplexitäten und erhalten die Gesamtkomplexität  $O(n \cdot log_2(n)^2)$ .

Lösung zu Aufgabe 7 Wir erkennen, dass es sich um einen rekursiv implementierten Algorithmus handelt, da die Funktion sich zweimal selbst aufruft. Daher findet hier das Mastertheorem Anwendung, da es sich um ein "Divide and Conquer"-Problem handelt.

- Es finden zwei Rekursive Aufrufe statt, also setzen wir a = 2.
- In jedem Rekursiven Aufruf halbieren wir die Datenmenge, also gilt b=2.
- Der Aufwand für das Zusammenfügen ist konstant, damit unerheblich und liegt daher in O(1).

Wir setzen zusammen und stellen die Gleichung für das Mastertheorem auf:

$$T(n) = 2 \cdot T(\frac{n}{2}) + O(n^0)$$

Nun tritt der dritte Fall des Mastertheorems ein, da  $2 > 2^0 = 1$  gilt. Wir erhalten als Gesamtkomplexität  $O(n^{\log_2(2)}) = O(n)$ .

- 26. Suchalgorithmen
- 27. Sortieralgorithmen
- 28. Bäume
- 29. Heaps

# Teil VIII.

1.

2.

# Verzeichnisse

### **Tabellen und Formeln**

## Abbildungsverzeichnis

3.	Allgemeiner binärer Baum									
4.	Beispiel für einen AVL-Baum									
5.	Kein Beispiel für einen AVL-Baum									
6.	AVL-Baum mit Rechtsrotation des Knotens 24									
7.	AVL-Baum mit Linksrotation des Knotens 24									
	Binärer Max-Heap									
	Binärer Max-Heap in Array-Darstellung									
	Herstellen der Heap-Eigenschaft durch swim_up(T) im ersten Schritt 44									
	Gerichteter Graph									
	Ungerichteter Graph zur Veranschaulichung der Adjazenzmatrix 51									
13.	Skizze zu Aufgabe 1.1									
Literat	ur									
[Enz20]	Brockhaus Enzyklopädie. Mohammed Ibn Musa Charismi. 2020. URL: https://brockhaus.de/ecs/enzy/article/charismi-mohammed-ibn-musa.									
[ESB16]	H. Ernst, J. Schmidt und G. Beneken. <u>Grundkurs Informatik</u> . Heidelberg: Springer, 2016.									
[Jan03]	Matthias Jantzen. <u>Berechenbarkeit und Komplexität</u> . 2003. URL: https://www.informatik.uni-hamburg.de/TGI/lehre/vl/WS0304/F3/F3-slides10-268-293.pdf.									
[Sch19]	Jochen Schmidt. <u>Grundkurs Informatik - Das Übungsbuch</u> . Springer, 2019.									
[Vöc+08]	B. Vöcking u. a. <u>Taschenbuch der Algorithmen</u> . Heidelberg: Springer, 2008.									
[Wik20]	Wikipedia. $\underline{\text{Knuth-Morris-Pratt-Algorithmus}}$ . 2020. URL: https://de.wikipediaorg/wiki/Knuth-Morris-Pratt-Algorithmus.									
[Wir83]	Niklaus Wirth. <u>Algorithmen und Datenstrukturen</u> . Stuttgart: B. G. Teubner, 1983.									
[WM20]	Kurt-Ulrich Witt und Martin Eric Müller. <u>Algorithmische Informationstheorie</u> . Heidelberg: Springer, 2020.									